Excel 활용 Big Data

『4과목』
Data Analysis와 확률/통계

2024.08.26-2024.08.30

Prepared by DaeKyeong Ki

Ph.D.

삼성전자 구미사업부

HS Global
HARDWARE SOFTWARE

목차

5 『3장』 추정과 가설검정

6 〃

7 『4장』 통계와 데이터 분석

8 〃

『3장』 추정과 가설검정

가설검정

Syllabus

학습목표

- 추정과 가설검정을 이해한다.

눈높이 체크

- 추정과 가설검정에 대해 들어 보셨나요?

1. 추정과 가설검정

통계적 추론[Inference Statistics, 추측통계]

- 수집된 자료를 이용해 대상 집단[모집단]에 대한 의사결정을 하는 것
- 제한된 표본을 바탕으로 모집단에 대한 일반적인 결론을 추정하는 것[본질적으로 불확실성 수반]

모수추정	표본집단으로부터 모집단의 특성인 모수[평균, 분산 등]을 분석해 모집단을 추론
가설검정	대상집단에 대한 특정 가설을 설정한 후 그 가설이 옳은지 그린지에 대한 채택여부를 결정하는 방법론
예 측	미래의 불확실성을 해결해 효율적인 의사결정을 하기 위해 활용 회귀분석, 시계열분석 등의 방법 사용

※ 추정 : 표본으로부터 모집단이 가지는 특성(모수)을 추측하는 것
※ 가설검정 : 자신이 가진 이론적 대안이 통계적으로 의미가 있는지를 확인하는 것

1. 추정과 가설검정

추정

- 통계적 추론[Inference Statistics, 추측통계]

1) 모수 추정

- 전수조사가 불가능할 때 모집단에서 표본을 추출하고 이를 근거로 확률론을 활용해 모집단의 모수들을 추론하는 것

점추정 [Point Estimation]	모수가 특정한 값일 것이라고 추정하는 것 표본의 평균, 중위수, 최빈값 등을 사용하는 것
구간추정 [Interval Estimation]	점추정의 정확성을 보완하기 위해 모수의 참값이 포함되어 있다고 추정되는 구간을 결정하는 것 실제 모집단의 모수가 신뢰구간에 꼭 포함되어 있는 것은 아님 구해진 구간 안에 모수가 있을 가능성의 크기[신뢰수준, Confidence Interval]가 주어져야 한다.

추정

● 추정

2) 구간 추정

- 점추정의 정확성을 보완하는 방법. 확률로 표현된 믿음의 정도(90%, 95%, 99%등) 하에서 모수가 특정한 구간(신뢰구간)에 있을 것이라고 선언하는 것.
- 항상 추정량의 분포에 대한 전제가 주어져야 하고, 구해진 구간에 대한 모수가 있을 가능성의 크기(신뢰 수준)가 주어짐
- 신뢰 수준 95% 의미
- 모집단에서 동일한 방법으로 확률 표본을 무한히 추출하여 신뢰구간을 구하면, 그중 95%의 신뢰구간이 미지의 모수를 포함한다는 의미(주어진 한 개의 신뢰구간이 미지의 모수를 포함할 확률이 95%라는 것과 구분해야 함)

모분산 σ^2이 알려져있는 경우	모분산 σ^2이 알려져있지 않는 경우
$z = \dfrac{\bar{X}-\mu}{\sigma/\sqrt{n}}$	표본본산 사용, $T = \dfrac{\bar{X}-\mu}{S/\sqrt{n}}$

2. 대표값의 추정-신뢰구간 구하기

평균값 추정

- 구간추정과 신뢰구간

- 평균값을 낀 신뢰구간의 폭이 정해지면 구할 수 있음
- 이 폭은 존재하는 가능성(신뢰계수)에 의해 정해지며, 가능성이 높을수록 폭이 넓어짐
- 모집단의 분산 σ2과 표본의 개수 n, 평균 $\bar{x}$ 를 알고 있다고 가정하면, 이 경우, 표본의 평균 $\bar{x}$ 는 정규분포 N(μ, σ2 /n)을 따라가므로$\bar{x}$를 표준화한 통계량은 표준정규분포 N(0, 1)을 따라가게 됨

$$\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}}$$

- 표준정규분포의 확률 1-α에 대응하는 표준정규분포의 값을 Z1-α로 하면, 부등식이 성립

$$-Z_{1-\alpha/2} \le \frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}} \le Z_{1-\alpha/2}$$

- 여기서 α를 결정하면 $\bar{x}$ 는 표본의 평균, σ는 이미 알고 있는 모집단의 표준편차, n은 표본의 개수이므로 μ 외의 모든 값을 알게 되므로 이 식을 μ에 대해 풀어보면 그 범위를 구할 수 있음

$$\bar{x}-Z_{1-\alpha/2}\times\left(\frac{\sigma}{\sqrt{n}}\right) \le \mu \le \bar{x}+Z_{1-\alpha/2}\times\left(\frac{\sigma}{\sqrt{n}}\right)$$

2. 대표값의 추정-신뢰구간 구하기

평균값 추정

● 표준정규분포

모집단의 분산을 사전에 알고 있는 경우는 일반적으로 있을 리 없으므로
실제로는 평균과 같이 표본으로부터 계산해낸 표본분산 s2을 사용
이 경우, 통계량이 자유도 n-1의 t 분포에 따른다는 점을 이용
t 분포도 [그림]의 표준정규분포와 같이 좌우대칭

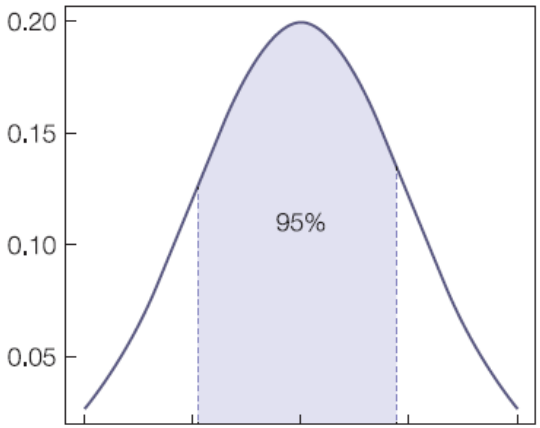

모평균값의 신뢰계수인 1-α의 신뢰구간은 표본의 평균을 x, 표본표준편차를 s로 지정하면, 신뢰구간 산출식

$$\bar{x} - t_{(\alpha/2,\, n-1)} \times \left(\frac{s}{\sqrt{n}}\right) \le \mu \le \bar{x} + t_{(\alpha/2,\, n-1)} \times \left(\frac{s}{\sqrt{n}}\right)$$

2. 대표값의 추정-신뢰구간 구하기

평균값 추정

- 모평균값의 95% 신뢰구간 구하기
- 파일 : Ex-15.xlsx

01 먼저 수축기 혈압의 평균값과 표본표준편차를 계산
평균값=AVERAGE(B2:B61) / 표본표준편차=STDEV.S(B2:B61)
02 자유도 59의 t 분포 0.025의 값을 계산
=T.INV.2T(0.025,59)

t(α/2, n-1)은 자유도 n-1의 t 분포 α/2의 값을 나타내며, 엑셀에서는 통계 함수 'T.INV.2T'를 사용해서 = T.INV.2T(α/2, n-1)과 같이 계산
지금 1-α가 95%이므로 α=0.05, α/2=0.025가 되고, n=60이므로 계산 결과를 출력할 셀에 =T.INV.2T(0.025,59)라고 입력
엑셀을 사용해서 실제로 계산해보면 수축기 혈압의 모평균값 μ의 95% 신뢰구간은 116.31≤μ≤128.22
모평균값 μ의 99% 신뢰구간은 114.71≤μ≤129.82

2. 대표값의 추정-신뢰구간 구하기

평균값 추정

03 t값이 2.300047로 구해졌으므로, 신뢰구간의 식을 적용해서 하한과 상한을 계산

하한=B62-B64*B63/SQRT(59) / 상한=B62+B64*B63/SQRT(59)

04 이 표에서는 하한이 [C62]셀에, 상한이 [C63]셀에 출력

7	56	101	
8	57	146	
9	58	113	
0	59	149	
1	60	153	
2		122.2666667	116.3089282
3		19.89622796	128.2244051
4		2.300046899	
5			
6			

2. 대표값의 추정-신뢰구간 구하기

분산 추정

모분산의 신뢰계수 1-α의 신뢰구간
평균값 $\bar{x}$, 모분산 σ2, 표본분산 s2에서 통계량이 자유도 n-1의 x2(카이제곱) 분포에 따르는 점을 이용

통계량 $$T=\frac{(x_1-\bar{x})^2+(x_2-\bar{x})^2+\cdots+(x_n-\bar{x})^2}{\sigma^2}=\frac{(n-1)s^2}{\sigma^2}$$

모분산의 신뢰계수 1-α의 신뢰구간 $$\frac{(n-1)s^2}{\chi^2_{(\alpha/2,\,n-1)}}\le\sigma^2\le\frac{(n-1)s^2}{\chi^2_{(1-\alpha/2,\,n-1)}}$$

2. 대표값의 추정-신뢰구간 구하기

분산 추정

파일 : Ex-15.xlsx

모분산의 95% 신뢰구간 구하기
01 먼저 수축기 혈압의 표본분산을 계산
=VAR.S(B2:B61)
02 자유도 59의 x2 분포 0.025와 0.075의 값을 계산
x2 분포 0.025 =CHISQ.INV.RT(0.025,59) / x2 분포 0.075=CHISQ.INV.RT(0.075,59)

x2(α/2, n-1)은 자유도 n-1의 확률 α/2의 χ2값으로, 엑셀에서는 통계 함수 'CHISQ.INV.RT'를 사용해서
= CHISQ.INV.RT(α/2, n-1)과 같이 구할 수 있음
1-α가 95%이고 α/2=0.025, n=60이므로 값을 구하고자 하는 셀에
=CHISQ.INV.RT(0.025, 59) 입력
실제로 엑셀을 사용해서 값을 구해보면 수축기 혈압의 모분산 σ2의 95% 신뢰구간은 284.42≤σ2≤310.26

2. 대표값의 추정-신뢰구간 구하기

분산 추정

03 신뢰구간의 하한과 상한 구하기

하한 =59*B62/B63 / 상한=59*B62/B64

04 이 표에서는 하한이 [C63]셀에, 상한이 [C64]셀에 출력

2. 대표값의 추정-신뢰구간 구하기

비율 추정

비율 추정
n명 중 m명이 어느 조건에 해당할 경우, 그 비율(p)은 $P=m/n$
비율의 1-α 신뢰구간은 m이 이항분포 B(n, p)를 따를때
통계량이 표준정규분포 N(0, 12)에 따른다는 점을 이용

통계량 $$\frac{m-np}{\sqrt{np(1-p)}}$$

비율의 신뢰구간 $$\frac{m-Z_{1-\alpha/2}\sqrt{np(1-p)}}{n} \le p \le \frac{m+Z_{1-\alpha/2}\sqrt{np(1-p)}}{n}$$

2. 대표값의 추정-신뢰구간 구하기

비율 추정

이항분포
동전을 던졌을 때 앞면이나 뒷면이 나오는 것처럼 결과가 둘 중 하나이고(A, B) 각각의 확률이 p, 1-p로 일정할 경우, 이를 n번 반복해서 시행한다고 가정
이때 A가 x번 일어난다면 B는 n-x번 일어나며, 따라서 그 확률은

$$f(x) = {}_nC_x p^x (1-p)^{n-x} \qquad x = 0, 1, \cdots, n$$

이 확률분포를 이항분포(binomial distribution)라고 부르며, Bi(n, p)와 같이 표현
X가 이항분포 Bi(n, p)에 따르는 경우,
기대값 E(X) = np
분산 V(X) = np(1-p)

2. 대표값의 추정-신뢰구간 구하기

비율 추정

파일 : Ex-15.xlsx

건강검진 데이터를 이용해서 총 콜레스테롤 이상자 비율의 95% 신뢰구간을 추정

건강검진 수험자 60명(n) 중 23명(m)이 220 이상

01 필요한 정보를 워크시트에 준비

n, m, p=m/n, 1-p, Z, 하한, 상한

02 순서대로 계산

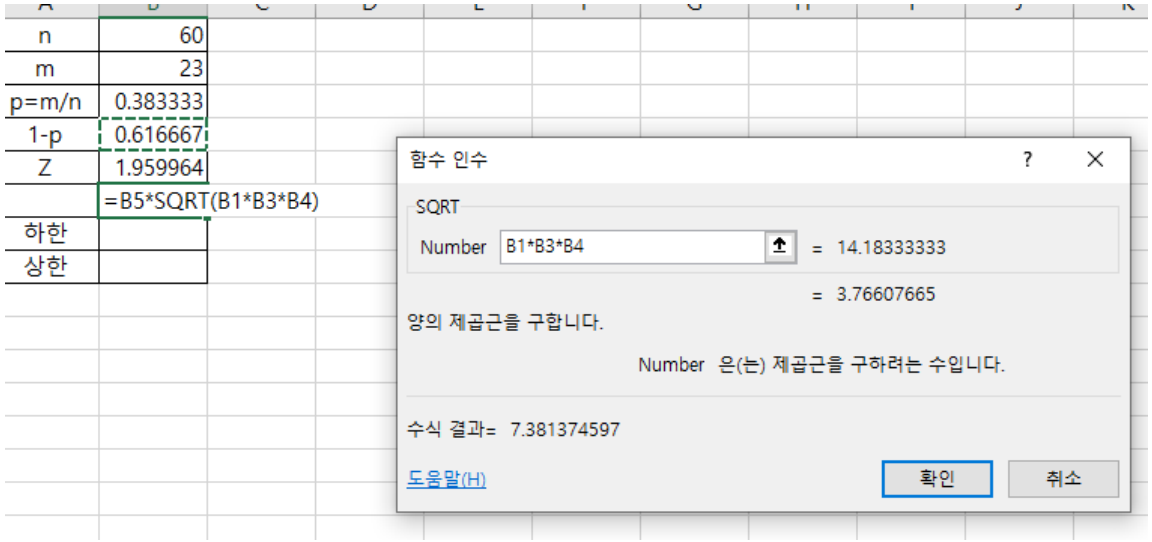

2. 대표값의 추정-신뢰구간 구하기

비율 추정

=B2/B1
=1-B3
=NORM.S.INV(0.975)
=B5*SQRT(B1*B3*B4)
=(B2-B6)/B1
=(B2+B6)/B1

	A	B	C	D
1	n	60		
2	m	23		
3	p=m/n	0.383333		
4	1-p	0.616667		
5	Z	1.959964		
6		7.381375		
7	하한	0.26031		
8	상한	0.506356		
9				
10				
11				
12				

가설검정

- 모집단에 대한 어떤 가설을 설정한 뒤에 표본관찰을 통해 그 가설의 채택여부를 결정하는 분석방법
- 표본관찰 또는 실험을 통해 귀무가설과 대립가설 중에서 하나를 선택하는 과정
- 귀무가설이 옳다는 전제하에 검정통계량 값을 구한 후에 이 값이 나타날 가능성의 크기에 의해 귀무가설의 채택여부를 결정

귀무가설 **[Null Hypothesis, H_0]**	현재까지 주장되어온 것이나 변화나 차이가 없음을 설명하는 가설
대립가설 **[Alternative Hypothesis, H_1]**	귀무가설에 반대되는 주장을 하는 가설로 귀무가설을 기각했을 때 받아들여지는 가설 실제 검정대상이 되는 가설은 아니다!
검정통계량 **[Test Statistic]**	관찰된 표본으로부터 구하는 통계량 검정 시 가설의 진위를 판단하는 기준
유의수준 **[Significance Level, α]**	귀무가설을 기각하게 되는 확률의 크기로 '귀무가설이 옳은데도 이를 기각하는 확률의 크기'
유의확률 **[p-value]**	귀무가설이 맞다고 정할 때, 표본통계량보다 극단적인 결과가 실제로 관측될 확률 p-value와 α를 비교하여 귀무가설 기각 여부를 결정[p-value<α이면 기각]
기각역 **[Critical Region,C]**	귀무가설을 기각시키는 검정통계량들의 범위[반대는 채택역(acceptance region)} 귀무가설이 옳다는 전제 하에서 구한 검정통계량의 분포에서 확률이 유의수준 α인 부분

추정과 가설검정

- 가설검정
- 제1종 오류와 제2종 오류

가설검정결과 / 정확한 사실	H0이 사실이라고 판정	H0이 사실이 아니라고 판정
H0이 사실임	옳은 결정	제 1종 오류
H0이 사실이 아님	제 2종 오류	옳은 결정

- 제1종 오류: 귀무가설 H0이 옳은데도 귀무가설을 기각하게 하는 오류
- 제2종 오류: 귀무가설 H0이 옳지 않은데도 귀무가설을 채택하게 하는 오류
- 제1종 오류와 2종 오류는 상충관계가 있어 일반적으로 가설검정에서는 제1종 오류의 크기를 0.1, 0.05, 0.01등으로 고정시킨 뒤 제2종 오류가 최소가 되도록 기각역 설정

3. 가설 검정

비모수 검정

- 통계적 검정에서 모집단의 모수에 대한 검정은 모수적 검정과 비모수적 검정으로 구분
  - 모수적 방법 : 검정하고자 하는 모집단의 분포에 대한 가정을 하고, 그 가정하에서 검정 통계량을 검정 통계량을 분포를 유도해 검정을 실시하는 방법
  - 비모수적 방법: 자료가 추출된 모집단의 분포에 대한 아무 제약을 가하지 않고 검정을 실시하는 방법. 관측된 자료가 특정 분포를 따른다고 가정할 수 없는 경우에 이용. 관측된 자료의 수가 많지 않거나 자료가 개체 간의 서열관계를 나타내는 경우 이용
- 모수 검정과 비모수 검정의 차이점

종류	모수적 검정	비모수 검정
가설의 설정	가정된 분포의 모수에 대해 가설의 설정	가정된 분포가 없으므로 가설은 단지 분포의 형태가 동일하다 또는 분포의 형태가 동일하지 않다
검정 방법	관측된 자료를 이용해 구한 표본평균, 표본 분산 등을 이용해 검정 실시	측값의 절대적인 크기에 의존하지 않는 관측값들의 순위나 두 관측값 차이의 부호 등을 이용해 검정

3. 가설 검정

통계량을 이용한 검정방법

- 평균값을 $\bar{x}$, 표본표준편차를 s, 모평균을 μ, 표본 수를 n으로 했을 경우 통계량은 자유도 n-1의 t 분포에 따름

$$T = \frac{\frac{\bar{x}-\mu}{s}}{\sqrt{n}}$$

3. 가설 검정

통계량을 이용한 검정방법

모평균값 검정
파일 : Ex-15.xlsx

평균값=AVERAGE(B2:B61)
표본표준편차=STDEV.S(B2:B61)
모평균값 120
T값=(B62-B64)/(B63/SQRT(60))
t분포값=T.INV.2T(0.025,59)

60	59	149
61	60	153
62	평균값	122.2666667
63	표본표준편차	19.89622796
64	모평균값	120
65	T값	0.882454933
66	t분포값	2.300046899
67		

3. 가설 검정

통계량을 이용한 검정방법

엑셀에서 위 식에 해당하는 값을 대입해서 T를 계산하여 그 값(절대값)과 자유도 59, p = a/2 = 0.025를 t 분포값과 비교

- T < T.INV.2T(0.025,59) = 2.30 → 귀무가설을 채택
- T > T.INV.2T(0.025,59) → 귀무가설을 기각

μ=120의 경우 T=0.8824가 되어서

T 는 0.882454933 < T.INV.2T(0.025,59) 는 2.30

과 같이 μ0=120의 경우 귀무가설이 채택되므로 모평균값은 120mmHg 라고 할 수 있음

4. 두 집단의 평균 차이 검정

두 집단 평균 차이 검정

두 집단 중 하나에 속하는 대상에 대해서 같은 방법으로 무언가를 측정했을 때,
  집단별로 '평균값에 차이가 있는지'를 비교해야 하는 경우
남녀별로 수축기 혈압을 측정했더니 [표 9-2]와 같은 결과가 도출
평균값을 보면 남성이 크지만, 표준편차는 작음
이때 정말로 평균값에 차이가 있고, 남성의 수축기 혈압 평균값이 여성에 비해서 크다고 할 수 있는지?

	인원수	평균값	표본분산	표본표준편차
남성	30	125.2	299.5	17.3
여성	30	119.3	488.0	22.1

4. 두 집단의 평균 차이 검정

검정 수행 단계

첫번째: 두 집단의 '산포도에 차이가 있는가', 즉 '분산이 같은가'에 대해서 검정
이 검정을 위해서는 두 집단의 표본분산의 비율을 구하고, 그 비율이 두 집단의 자유도의 F 분포에 따른다는 점을 이용
엑셀로 계산하려면 통계 함수 'FTEST'를 이용해서 비교할 두 데이터를 지정
분산이 동일한지 아닌지에 따라 검정 통계량을 구하는 식이 다르기 때문에 이 과정을 생략하면 안되기 때문에 분산의 비율을 구해서 F 분포에 따른 검정을 수행

4. 두 집단의 평균 차이 검정

검정 수행 단계

두번째: 두 집단의 평균값과 표본분산을 각각 x, sx2, y, sy2으로 두고 평균값의 차를 검정
두 집단 간에 등분산이 성립할 경우,

두 집단을 합친 분산은, $s^2 = \frac{(n_x-1)s_x^2+(n_y-1)s_y^2}{n_x+n_y-2}$ 검정 통계량 $T = \frac{x-y}{s\sqrt{\frac{1}{n_x}+\frac{1}{n_y}}}$ 가

자유도 nx +ny -2의 t 분포 t (nx +ny -2)에 따르는 점을 이용해서 검정을 수행
두 집단 간에 등분산이 성립하지 않을 경우,

검정 통계량 $T = \frac{x-y}{s\sqrt{\frac{s_x^2}{n_x}+\frac{s_y^2}{n_y}}}$ 가, 자유도 $\frac{\left(\frac{s_x^2}{n_x}+\frac{s_y^2}{n_y}\right)^2}{\frac{\left(\frac{s_x^2}{n_x}\right)^2}{n_x-1}+\frac{\left(\frac{s_y^2}{n_y}\right)^2}{n_y-1}}$ 의 t 분포에 따른다는 점을

이용해서 검정을 수행

4. 두 집단의 평균 차이 검정

검정 수행 단계

검정 결과에 영향을 미치는 요인
두 집단의 평균 차이를 검정할 때 검정 결과가 유의한지는 검정 통계량 (T)의 크기에 의존
T가 크면 클수록 검정 결과가 유의함
이는 검정 전반에 공통으로 적용되므로, 두 집단의 평균 차이 검정에만 한정되지 않음
검정 통계량 T를 키우려면 당연히 두 집단의 차인 x-y가 커져야 하지만, 두 집단의 대상 수에도 영향을 받음
반면, 대상 수가 극단적으로 커지게 되면 두 집단 간에 차이가 거의 없더라도 유의차가 발생하게 됨에 주의

$$T = \frac{x-y}{s\sqrt{\frac{1}{n_x}+\frac{1}{n_y}}}$$

4. 두 집단의 평균 차이 검정

검정 수행 단계

파일 : Ex-15.xlsx
01 성별과 수축기 혈압의 값이 들어 있는 워크시트를 준비
여기서는 '데이터 '에서 필요한 데이터만 추출해서 사용

귀무가설 H0 : 남성과 여성의 수축기 혈압 평균값에 차이가 없음
대립가설 H1 : 남성과 여성의 수축기 혈압 평균값에 차이가 있음

먼저 FTEST 함수를 이용해서 비교할 두 데이터를 지정
=FTEST(C2:C31,C32:C61)

02 등분산이 성립하는 것을 확인했으면, 이번에는 TTEST 함수를 이용해서 검정을 수행
=TTEST(C2:C31,C32:C61,2,2)

4. 두 집단의 평균 차이 검정

검정 수행 단계

엑셀로 계산하는 경우에는 통계 함수 'FTEST'를 사용해서 =FTEST(x, y)와 같이 입력
검정을 위한 확률이 유의 수준(0.05)보다 큰 0.195로 구해지므로 두 집단의 모분산에 차이가 없다는 것을 알 수 있음
모분산에 차이가 없다는 것을 확인했으면, TTEST 함수를 사용해서 =TTEST(x, y, 2, 2)와 같이 입력
검정을 위한 확률이 0.2569로 구해지는데, 유의 수준(0.05)보다 큰 값이므로 귀무가설이 채택되어
'남녀 간의 수축기 혈압 평균값에 차이가 있다고는 할 수 없다'라고 판단이 가능

50	58	2	113
51	60	2	153
52			0.194755
53			0.256909
54			
55			

4. 두 집단의 평균 차이 검정

검정 수행 단계

두 집단의 평균 차이 검정
앞서 다루었던 검정 방법에서는 분석 대상이 '무언가의 속성에 의해 두 집단으로 분류'되어서 모든 대상에 대해
동일한 방법으로 동일 항목을 측정한 경우만 가능.
집단에 따라 측정 방법이 달라지는 경우에는 이 분석 방법을 사용할 수 없으므로 주의
검정을 수행할 때의 '데이터 분포 상황'에 대한 이 검정의 요구사항은 각 집단의 분포가 정규분포에 근사해야 함

4. 두 집단의 평균 차이 검정

검정 수행 단계

엑셀에서 계산하려면 통계 함수 'TTEST'를 =TTEST(x, y, 2, m)과 같이 사용해서 계산
등분산의 경우에는 m=2, 그렇지 않은 경우에는 m=3을 넣고 비교할 두 데이터를 지정하면 검정을 위한 확률이 구해짐

4. 두 집단의 평균 차이 검정

대응표본 평균 차이 검정

동일 대상자에 대해 동일한 측정값의 평균을 비교하는 방법
두 개의 '대응 관계인 값의 평균이 0인지'를 검정
중장년층 60명의 수축기 혈압을 5년 전과 이번에 각각 측정하였음
평균값은 5년 전에 120.0mmHg, 이번에는 122.3mmHg
그렇다면 5년간 수축기 혈압 값에 변화가 있었다고 할 수 있을까?
이 경우, 동일 대상자에 대해 동일한 측정을 2회 수행함

	평균값	표본표준편차
수축기 혈압	122.3	19.9
수축기 혈압 5년 전	120.0	31.2

4. 두 집단의 평균 차이 검정

대응표본 평균 차이 검정

귀무가설 H0 : 5년 전과 지금의 수축기 혈압 평균값에 차이가 없음
대립가설 H1 : 5년 전과 지금의 수축기 혈압 평균값에 차이가 있음

예제 파일 Ex-15.xlsx
대응 관계인 평균값의 차이를 검정
01 현재의 수축기 혈압과 5년 전의 수축기 혈압의 값이 들어 있는 워크시트를 준비
    TTEST 함수로 계산 =TTEST(B2:B61,C2:C61,2,1)
02 검정을 위한 확률이 산출

4. 두 집단의 평균 차이 검정

대응표본 평균 차이 검정

엑셀 통계 함수 'TTEST'를 사용해서 =TTEST(x, y, 2, 1)과 같이 입력하면 대응표본 평균 차이 검정을 위한 확률을
구할 수 있음
빈 셀에 =TTEST(B2:B61, C2:C61,2,1)이라고 입력하면 검정을 위한 확률이 0.6749로 산출
이 값이 유의 수준인 5%(=0.05)보다 크기 때문에 귀무가설이 채택되므로, 5년 전과 지금의 수축기 혈압 평균에 차이가 있다고 할 수는 없음

59	149	111
60	153	103
		0.674926

5. 집단이 셋 이상인 경우의 평균 차이 검정

일원배치 분산 분석

3개 이상의 집단에 대한 평균 차이를 검정하는 방법
군간분산과 군내분산의 비를 검정 통계량으로 삼아 검정을 수행
검정에 필요한 귀무가설은 지금까지와 동일하게 '평균값에 차이가 없음
모든 대상의 변동(총변동 ST):

$$S_T = \sum_{i=1}^{n}(x_i - \bar{x})^2$$

군내변동 SE : 모든 대상이 m개(j = 1, ⋯, m)의 집단으로 나뉜다고 했을 때, 집단 내의 변동의 합

$$S_E = \sum_{j=1}^{m}\sum_{k=1}^{n_j}(x_{jk} - \bar{x}_j)^2$$

군간변동 SA : 집단 간의 변동(=총변동 ST - 집단 내의 변동SE) $S_A = S_T - S_E$
집단 간의 평균 제곱(군간분산 VA)과 집단 내의 평균 제곱(군내분산 VE)

$$\begin{cases} V_A = S_A \div (m-1) \\ V_E = S_E \div (n-m-1) \end{cases}$$

비율 VA/VE(F값)가 자유도 (m-1, n-m-1)의 F 분포에 따른다는 점을 이용해 검정을 수행
엑셀 통계 함수 'FDIST'를 = FDIST(VA/VE, m- 1, n-m-1) 과 같이 사용하면 검정에 필요한 확률을 구할 수 있음

5. 집단이 셋 이상인 경우의 평균 차이 검정

일원배치 분산 분석

귀무가설 H0 : 30대, 40대, 50대의 수축기 혈압 평균값에 차이가 없음
대립가설 H1 : 30대, 40대, 50대의 수축기 혈압 평균값에 차이가 있음

예제 파일 Ex-15.xlsx

01 수축기 혈압 값을 연령순으로 정렬한 워크시트를 준비
집단별 변동과 총변동을 구한 후 군내변동, 군간변동, 군내분산, 군간분산 산출
총변동 =DEVSQ(C2:C61) / 검정용 확률 =FDIST(D67,2,56)
02 검정을 위한 확률이 산출

5. 집단이 셋 이상인 경우의 평균 차이 검정

일원배치 분산 분석

엑셀 통계 함수 DEVSQ 사용하여 30대, 40대, 50대의 변동을 계산
30대 변동: =DEVSQ(C2:C21)

총변동 ST: =DEVSQ(C2:C61)

군내변동 SE: 30대, 40대, 50대 변동의 합

군내변동=D21+D41+D61
군간변동=D62-D63
군내분산=D63/(60-3)
군간분산=D64/(3-1)
F값=D66/D65
검정을 위한 확률=FDIST(D67,2,56)

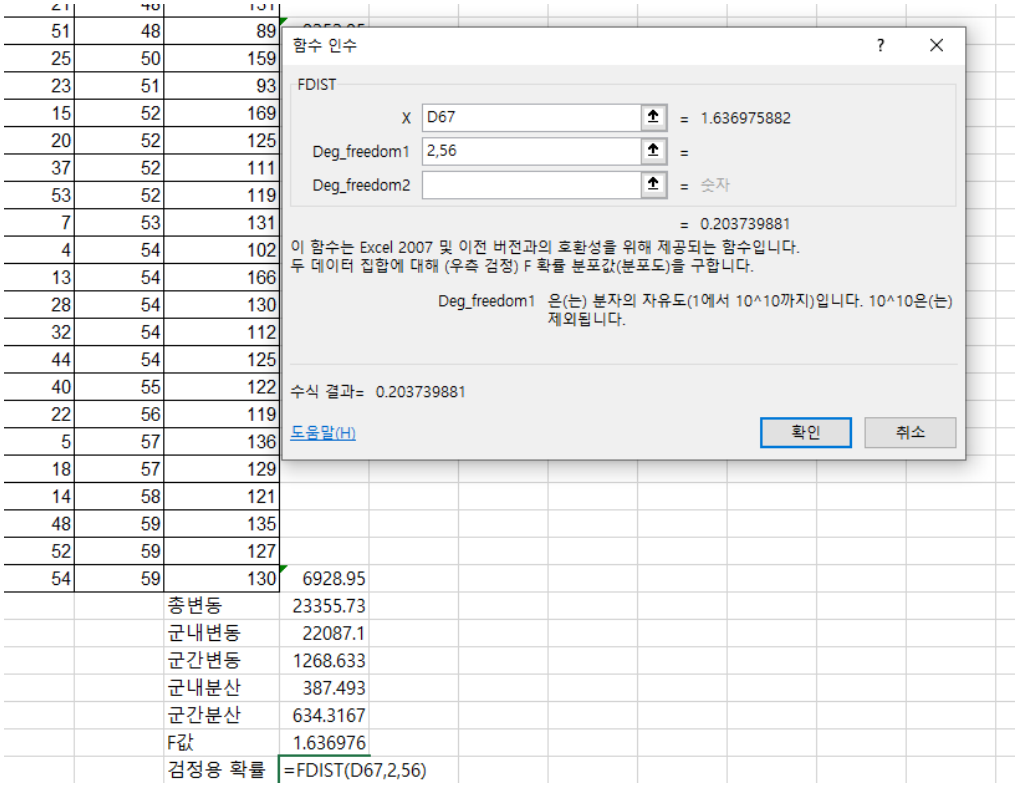

51	48	89	
25	50	159	
23	51	93	
15	52	169	
20	52	125	
37	52	111	
53	52	119	
7	53	131	
4	54	102	
13	54	166	
28	54	130	
32	54	112	
44	54	125	
40	55	122	
22	56	119	
5	57	136	
18	57	129	
14	58	121	
48	59	135	
52	59	127	
54	59	130	6928.95
		총변동	23355.73
		군내변동	22087.1
		군간변동	1268.633
		군내분산	387.493
		군간분산	634.3167
		F값	1.636976
		검정용 확률	=FDIST(D67,2,56)

5. 집단이 셋 이상인 경우의 평균 차이 검정

일원배치 분산 분석

산출 결과:
총변동 23355.73 / 군내변동 22087.1 / 군간변동 1268.633
군내분산 387.493 / 군간분산 634.317 / F값은 1.637 / 검정을 위한 확률 0.204
귀무가설이 채택되므로 30대, 40대, 50대 간에 차이가 있다고는 할 수 없음

6. 분석 도구 이용

일원배치 분산 분석

수축기 혈압 값을 30대, 40대, 50대별

01 비교할 그룹별로 열을 만들고, 분석할 데이터를 해당 열에 각각 배치, 또는 예제 파일을 불러오기

02 [데이터] 탭 - [분석] 그룹에서 [데이터 분석] - [통계 데이터 분석] 대화상자의 [분석 도구] 중

'분산 분석: 일원 배치법'을 선택하고 [확인] 클릭

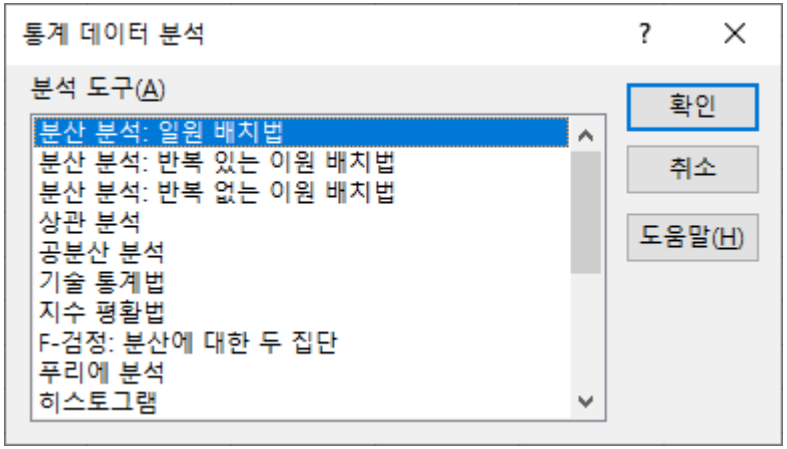

	A	B	C	D
1	30대	40대	50대	
2	126	122	159	
3	112	149	93	
4	127	153	169	
5	172	137	125	
6	118	92	111	
7	116	121	119	
8	109	111	131	
9	125	111	102	
10	104	100	166	
11	137	165	130	
12	116	101	112	
13	113	122	125	
14	110	147	122	
15	97	116	119	
16	105	146	136	
17	107	93	129	
18	94	124	121	
19	138	109	135	
20	103	131	127	
21	107	89	130	

6. 분석 도구 이용

일원배치 분산 분석

'분산 분석: 일원 배치법'을 선택하고 [확인] 클릭

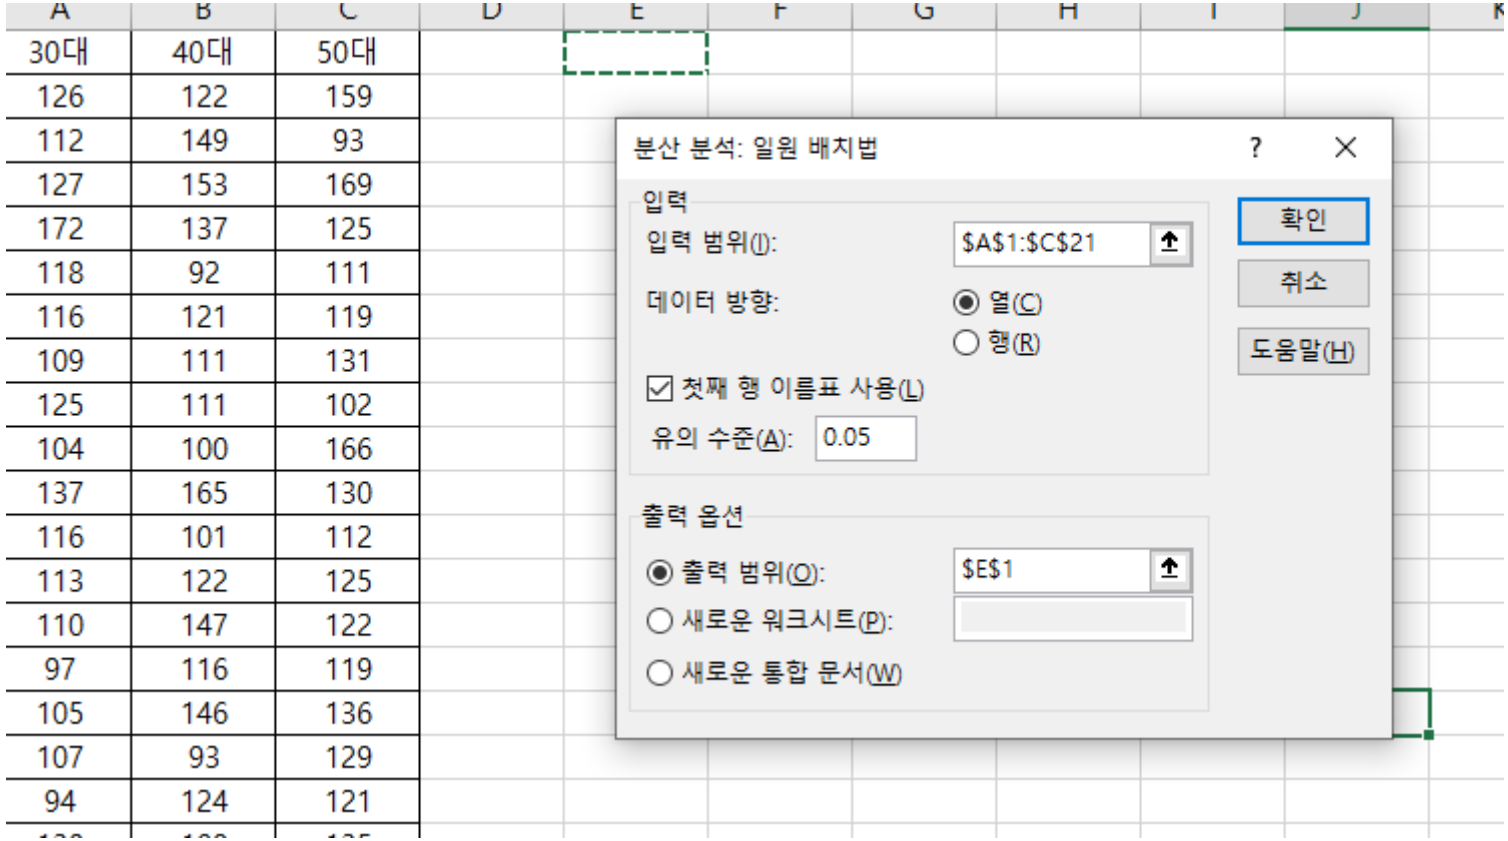

6. 분석 도구 이용

일원배치 분산 분석

03 [분산 분석: 일원 배치법] 대화상자의 [입력 범위]에는 앞서 수정했던 데이터의 셀 범위를 지정
출력에는 [7]열 [15]행이 필요하므로, [출력 범위]에는 넓이가 그 이상되는 셀 범위를 지정. 지정이 끝나면 [확인]

04 결과 출력

A	B	C	D	E	F	G	H	I	J	K	L
30대	40대	50대		분산 분석: 일원 배치법							
126	122	159									
112	149	93		요약표							
127	153	169		인자의 수준	관측수	합	평균	분산			
172	137	125		30대	20	2336	116.8	310.8			
118	92	111		40대	20	2439	121.95	486.9974			
116	121	119		50대	20	2561	128.05	364.6816			
109	111	131									
125	111	102									
104	100	166		분산 분석							
137	165	130		변동의 요인	제곱합	자유도	제곱 평균	F 비	P-값	F 기각치	
116	101	112		처리	1268.633	2	634.3167	1.636976	0.203581	3.158843	
113	122	125		잔차	22087.1	57	387.493				
110	147	122									
97	116	119		계	23355.73	59					
105	146	136									
107	93	129									
94	124	121									
138	109	135									
103	131	127									
107	89	130									

$p-$값을 이용한 검정방법

- $p-$값을 이용한 가설검정 절차

① 귀무가설 H_0 와 대립가설 H_1을 설정한다.
② 유의수준 $\propto$를 정한다.
③ 적당한 검정통계량을 선택한다.
④ $p-$값을 구한다.
⑤ $p-$값 $\leq \propto$ 이면 귀무가설을 기각하고, $p-$값 $> \propto$ 이면 귀무가설을 채택한다.

『4장』 통계와 데이터 분석

상관분석

회귀분석

Syllabus

학습목표

- 상관분석(Correlation Analysis)을 할 수 있다.

눈높이 체크

- 상관분석(Correlation Analysis) 을 알고 계신가요?

1. 상관분석

인과관계의 이해

- 종속변수(반응변수, y): 다른 변수의 영향을 받는 변수
- 독립변수(설명변수, x): 영향을 주는 변수

- 산점도
  - 좌표평면 위에 점들로 표현한 그래프
  - * 산점도에서 확인할 사항: 두 변수 사이의 선형 관계 성립 / 두 변수 사이의 함수 관계 성립 / 이상 값 존재 / 몇 개의 집단으로 구분

- 공분산
  - 두 확률 X,Y의 조합(선형성)이다.
  - 공분산 부호만으로 두 변수의 방향성을 확인할 수 있다(+이면 양의 방향성, -이면 음의 방향성)
  - X,Y가 서로 독립이면 Cov(X,Y)=0이다.
  - Cov(X, Y) = E(XY) - E(X)E(Y)

1. 상관분석

상관분석?

- 두 변수 간의 관계의 정도를 알아보기 위한 분석방법
- 두 변수의 상관관계를 알아보기 위해 사용

- 상관관계의 특성

상관계수 범위	해석
$0.7 < \gamma \le 1$	강한 양(+)의 상관이 있다.
$0.3 < \gamma \le 0.7$	약한 양(+)의 상관이 있다.
$0 < \gamma \le 0.3$	거의 상관이 없다.
$\gamma = 0$	상관관계(선형, 직선)가 존재하지 않음
$-0.3 \le \gamma < 0$	거의 상관이 없다.
$-0.7 \le \gamma < -0.3$	약한 음(-)의 상관이 있다.
$-1 \le \gamma < -0.7$	강한 음(-)의 상관이 있다.

1. 상관분석

상관분석의 개념

- 상관분석과 상관관계
  - 상관분석이란 두 변수 간에 관계가 있는지를 알아보고자 할 때 실시하는 분석방법
  - 상관관계란 두 변수(대상)이 서로 관련성이 있다고 추측되는 관계
- 상관계수(r)
  - 상관분석에서 두 변수의 관련된 정도를 나타내주는 값

1. 상관분석

상관분석의 개념

- X라는 양적 자료가 증가할수록 Y라는 양적 자료가 증가하면 양의 상관관계가 있다 고 하며, X가 증가할수록 Y가 감소하면 음의 상관관계가 있다고 한다. 하지만 X가 증 가하더라도 Y의 값이 별개로 있으면 상관관계가 없다고 할 수 있다. 두 양적 자료의 관련성 정도는 상관계수(coefficient of correlation)인 r로 표현되고, r은 -1 ~ +1의 사 이의 값을 가지고, r의 절대값이 1에 가까울수록 관련성이 높고, r의 절대값이 0에 가까울수록 관련성이 없다고 판단한다.

상관계수의 값	$-1 \le r \le 1$

1. 상관분석

공분산

- 두 확률변수 사이의 관계를 선형관계로 나타낼 때 두 변수 사이 상관의 정도를 나타내며 다음과 같이 구한다.

$$Cov(X,\ Y) = E[(X-E(X))(Y-E(Y))]$$
$$= E[(X-\mu_X)(Y-\mu_Y)], \quad E(X)=\mu_X,\ E(Y)=\mu_Y$$

- 두 확률변수 X, Y의 공분산은 $Cov(X,\ Y)$로 표기하고, 공분산이 갖는 값에 따라 두 확률변수의 관계를 확인할 수 있습니다.
- $Cov(X,\ Y)>0$: 두 확률변수 X, Y 의 변화가 같은 방향임을 나타냅니다. 즉 X 증가하면 Y 도 증가하고, 반대로 한 변수가 감소하면 같이 감소한다.
- $Cov(X,\ Y)>0$: 두 확률변수 X, Y 의 변화가 같은 방향임을 나타냅니다. 즉 X 증가하면 Y 도 증가하고, 반대로 한 변수가 감소하면 같이 감소한다.
- $Cov(X,\ Y)=0$: 두 확률변수 간에 어떠한 (선형) 관계가 없음을 나타냅니다.

1. 상관분석

공분산

- $$S_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})$$

$$= \frac{1}{n}\{(x_1 - \overline{x})(y_1 - \overline{y}) + (x_2 - \overline{x})(y_2 - \overline{y}) + \cdots + (x_n - \overline{x})(y_n - \overline{y})\}$$

1. 상관분석

상관계수(correlation coefficient)

- 상관도
  - 두 변량 사이의 관계를 대략적으로 파악할 수 있는 그래프
- 단순상관계수
  - 상관도의 양상이 대체로 직선인 경우
- 상관분석
  - 변수 사이의 직선 관계를 상관계수를 이용하여 분석하는 것

- 상관분석은 변수들 간의 단순한 상호 관계성의 정도를 분석하는 통계적 기법
- 상관분석은 두 변수의 순서쌍으로 구성된 표본요소에 대해서 두 변수간의 상관관계를 표본 상관계수를 통해 나타냄

1. 상관분석

상관계수(correlation coefficient)

- 두 확률변수 X, Y의 공분산을 각 확률변수의 표준편차의 곱으로 나눈 값을 (모)상관계수라 하고, 기호로 ρ_XY (혹은 ρ)로 나타낸다.

$$\rho_{XY} = \frac{Cov(X,\ Y)}{\sigma_X \sigma_Y} = \frac{E[(X-E(X))(Y-E(Y))]}{\sigma_X \sigma_Y}$$

$$\rho_{XY} \equiv Corr(X,Y) = \frac{Cov(X,Y)}{\sigma_X \sigma_Y} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

- (모)상관계수는 -1부터 1사이의 값을 가진다.
  - 공분산의 경우 자료의 단위에 따라 값의 크기가 일정하지 않아 비교하기 힘들다.
  - 공분산의 성질을 그대로 이어 받아 두 변수 간의 변화의 방향이 같으면 양수, 반대이면 음수를 갖는다.
- (모)상관계수는 모집단의 특성 중에 하나로 일반적으로 알 수 없으며, 두 확률변수로부터 추출한 표본의 특성을 통해 구하는 (피어슨의) 표본상관계수를 이용하여 추정한다.

1. 상관분석

상관계수(correlation coefficient)

- 상관계수의 특성

① ρXY의 범위는 -1≤ρXY≤1

② 두 변수가 서로 독립이면 두 변수 간에 상관관계가 없으며, ρXY =0

③ ρXY =0 이면 두 변수 간에 상관관계(선형관계)가 없다. 그러나 비선형관계는 있을 수 있기 때문에 두 변수가 서로 독립이라는 보장은 없다.

④ X와 Y가 정규분포를 따르는 경우, ρXY =0 이면 X와 Y는 독립

⑤ 양의 상관은 1에 가까워지고, 음의 상관은 -1에 가까워지고, 무상관은 0

$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{S_x}\right)\left(\frac{y_i - \bar{y}}{S_y}\right)$$

공분산 계산

엑셀을 이용한 이산형 확률변수의 공분산 계산

□ 두 확률변수들 간의 결합확률분포표로 주어진 경우에는 앞에서 계산한 방법과 같이 각각의 셀들 간의 연산을 통해 평균 등을 구해 공분산 공식에 대입해야 한다.

□ 그렇지 않고, 단지 두 변수들의 관찰치만 주어진 경우에는 통계함수 중에서 **COVAR()**함수를 이용하여 구할 수 있다.

[엑셀을 이용한 공분산 계산]

- 결합확률 분포표로 주어진 경우:

  ① X와 Y의 평균과 분산을 구한다.

  ② $\sum_i \sum_j x_i y_j p(x_i, y_j)$ 값을 셀 끼리의 연산을 통해 구한다.

  ③ 마지막으로 $\sigma_{xy} = \sum_i \sum_j x_i y_j p(x_i, y_j) - \mu_x \mu_y$ 를 구한다.

- 두 변수들의 관찰치로 주어진 경우:

  함수마법사의 통계함수 중에서 **COVAR( )** 함수를 이용한다.

  =COVAR(Y의 범위, X의 범위)

  참고로 관찰치로 주어진 데이터에 대한 공분산 계산 공식(**COVAR()**함수)

$$\sigma_{xy} = Cov(X, Y) = \frac{1}{n} \sum (X_i - \bar{X})(Y_i - \bar{Y})$$

공분산 계산

다음 결합확률분포표로부터 엑셀을 이용하여 X와 Y의 공분산을 구하라.

X \ Y	0	1	2	3
1	1/8	1/8	0	0
2	0	1/4	0	1/4
3	0	0	1/8	1/8

⌐ 풀이

다음과 같이 엑셀에 결합확률분포표를 입력하고, 공분산 공식에 포함되는 각 구성요소에 대한 값을 구하여 결과적으로 계산된 공분산 $\sigma_{xy} = Cov(X,Y) = 0.5$ 이다.

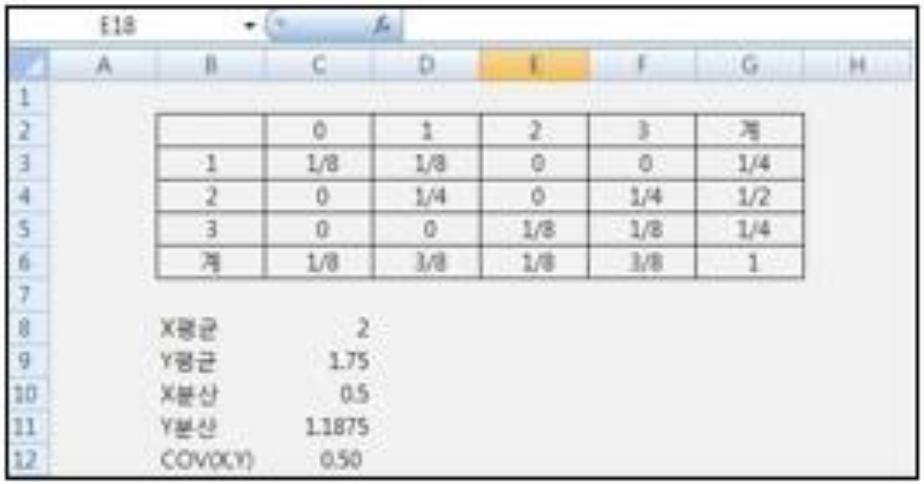

	0	1	2	3	계
1	1/8	1/8	0	0	1/4
2	0	1/4	0	1/4	1/2
3	0	0	1/8	1/8	1/4
계	1/8	1/8	1/8	1/8	1

X평균	2
Y평균	1.75
X분산	0.5
Y분산	1.1875
COV(X,Y)	0.50

퀴즈 1-5

다음과 같이 두 변수에 대한 자료가 있을 때, 엑셀을 이용하여 두 변수 X와 Y의 공분산을 구하라

X	12	14	15	13
Y	22	21	18	20

☞ 풀이

엑셀의 함수마법사중 통계함수에서 COVAR() 함수를 입력하고, X의 데이터범위와 Y의 데이터범위를 각각 입력한다.

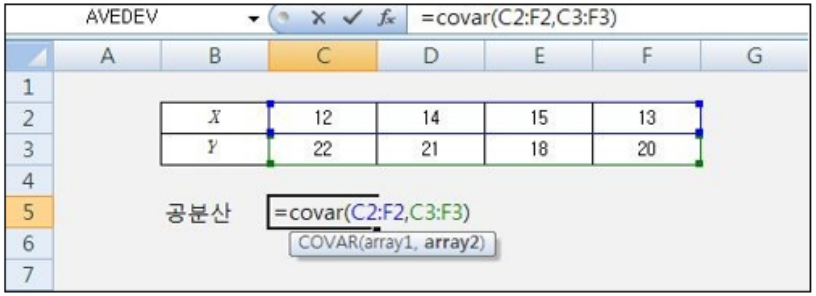

퀴즈 1-5

결과적으로 구하고자 하는 공분산은 $\sigma_{XY} = Cov(X, Y) = -1.375$ 이다.

C5 =COVAR(C2:F2,C3:F3)

	A	B	C	D	E	F	G
1							
2		X	12	14	15	13	
3		Y	22	21	18	20	
4							
5		공분산	-1.375				
6							

상관계수 계산

[엑셀을 이용한 이산확률 변수의 상관계수 계산]

- 결합 확률분포표로 주어진 경우

① 두 확률변수 $V(X)$ 와 $V(Y)$: 의 평균을 각각 u_x, u_y 를 구한다.

② 다음으로 분산 $V(X) = \sigma^2_x$, $V(Y) = \sigma^2_y$ 을 각각 구한다.

③ 공분산을 $Cov(X, Y) = \sigma_{xy}$ 을 구한다.

④ 상관계수 공식을 이용하여 값을 구한다.

- 관찰치로 주어진 경우 :
  함수 마법사의 통계함수 중 **CORREL()**함수를 이용하여 구한다.

  =CORREL(X의 데이터범위, Y의 데이터범위)

참고로 관찰치로 주어진 자료를 이용한 상관계수 공식은 다음과 같다.

$$p_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y} = \frac{Cov(X, Y)}{\sqrt{V(X)}\sqrt{V(Y)}}$$

$$= \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2}\sqrt{\sum (Y_i - \bar{Y})^2}}$$

상관계수 계산

예제 파일 Ex-16.xlsx

2개의 변수 데이터를 이용해서 상관계수를 실제로 계산 (통계 함수 'CORREL' 사용)

01 [함수 마법사] - [함수 검색]에 'CORREL'을 입력하고 [검색] 클릭

02 [함수 선택]에 'CORREL'을 더블클릭

03 [함수 인수] 대화상자에서 [Array1]에는 변수 X 표준화 사망률을, [Array2]에는 변수 Y 평균 수명(남성)을 지정

[Array1]과 [Array2]의 데이터 수는 반드시 일치해야 함

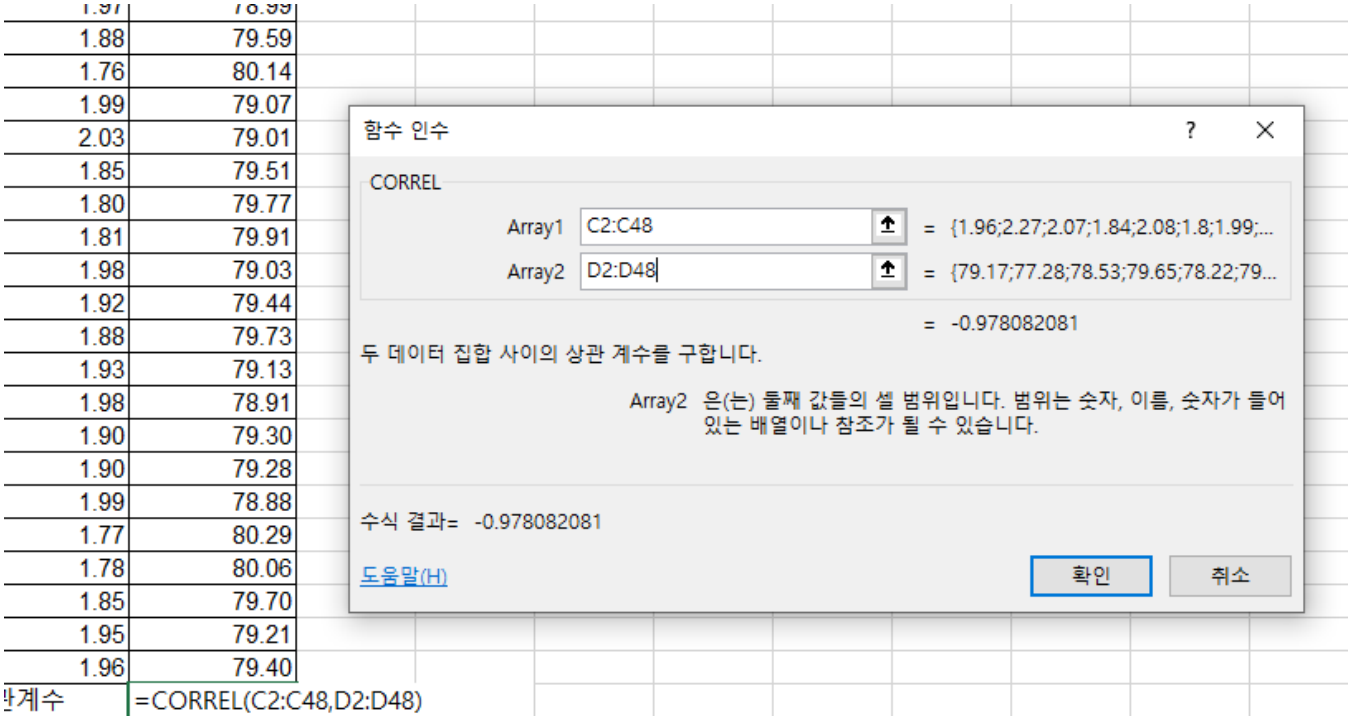

1. 상관분석

상관계수 계산

04 [수식 결과]로 '-0.978082081'이 출력되며, [확인] 버튼을 클릭하면 셀에 해당 값이 출력

즉, 이 두 변수의 상관계수는 -0.978이라는 결과

45	1.85	79.70
46	1.95	79.21
47	1.96	79.40
	상관계수	-0.978082081

1. 상관분석

상관 행렬 계산

엑셀의 [데이터 분석]을 사용해서 '데이터 03'의 13개 변수 간 상관관계를 계산

01 [데이터] - [분석] - [데이터 분석] - [통계 데이터 분석] - [분석도구] '상관 분석'을 선택하고 [확인] 클릭

02 [상관 분석] 대화상자에서 [입력 범위]를 지정하고 [출력 옵션]을 '새로운 워크시트'로 선택하고 [확인] 클릭

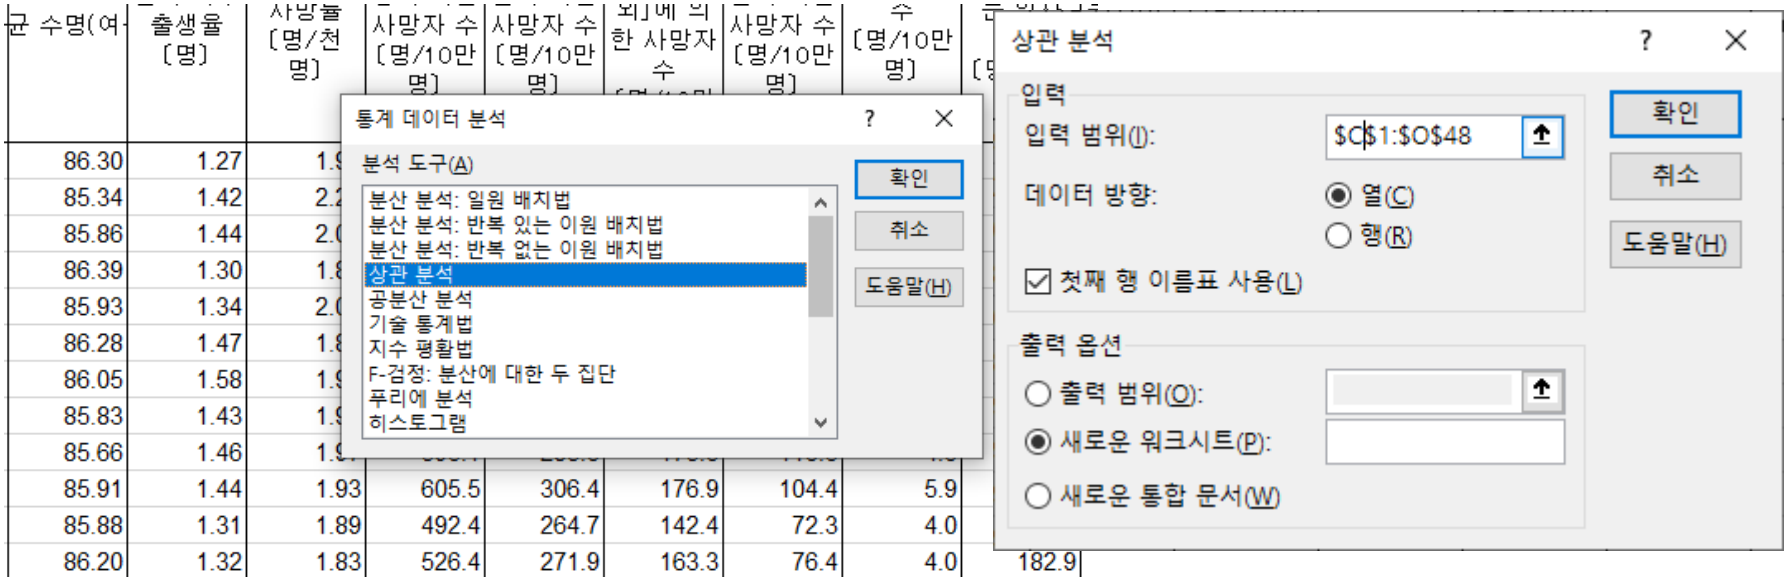

1. 상관분석

상관 행렬 계산

03 새로운 워크시트가 추가되면서 다음과 같이 상관 분석의 결과 생성

	일본인 인구 [명]	균 수명(남	균 수명(여	합계 특수 출생률 [명]	표준화 사망률 [명/천 명]	생활습관 병에 의한 사망자 수 [명/10만 명]	악성신생물에 의한 사망자 수 [명/10만 명]	허혈성 심질환 [고혈압성 제외] 에 의한 사망자 수 [명/10만 명]	뇌혈관질환에 의한 사망자 수 [명/10만 명]	일반 병원 수 [명/10만 명]	의료시설에 종사하는 의사 수 [명/10만 명]	의료시설에 종사하는 간호사 수 [명/10만 명]	1 인당 국민 의료비 [엔]
일본인 인구 [명]	1												
균 수명(	0.1415181	1											
균 수명(	-0.143956	0.682155	1										
합계 특수 출생률 [명]	-0.583471	-0.016761	0.3034221	1									
표준화 사망률 [명/천 명]	-0.125137	-0.978082	-0.736176	0.0529441	1								
생활습관 병에 의한 사망자 수 [명/10만 명]	-0.608448	-0.523123	-0.230383	0.1857179	0.4730026	1							
악성신생물에 의한 사망자 수 [명/10만 명]	-0.499208	-0.592278	-0.262109	0.1057131	0.5354287	0.9409116	1						
허혈성 심질환 [고혈압성 제외] 에 의한 사망자 수 [명/10만 명]	-0.595188	-0.362148	-0.185657	0.1874451	0.33748	0.9000501	0.7569694	1					
뇌혈관질환에 의한 사망자 수 [명/10만 명]	-0.584736	-0.418363	-0.156516	0.2276086	0.3634082	0.8828732	0.7611672	0.7069078	1				
일반 병원 수 [명/10만 명]	-0.411339	-0.174969	0.1734913	0.3832098	0.1721817	0.4375096	0.4483299	0.4443761	0.2531456	1			
의료시설에 종사하는 의사 수 [명/10만 명]	-0.104313	0.0524129	0.310943	0.1745182	-0.045454	0.0787665	0.1690603	0.0987091	-0.123173	0.5931751	1		
의료시설에 종사하는 간호사 수	-0.534785	-0.216927	0.2388424	0.578513	0.2060927	0.5026469	0.5365622	0.4544368	0.3283981	0.9015655	0.6376571	1	

표본상관계수(sample correlation coefficient)

- **모상관계수**
- 표준화된 공분산을 두 변량 X 와 Y 사이의 모상관계수 p 라고 하며, 다음과 같다.

$$\rho = \frac{\mathrm{Cov}(X,\ Y)}{\sigma_X \sigma_Y}$$

1. 상관분석

표본상관계수(sample correlation coefficient)

- **피어슨의 상관계수**
- 정식 명칭은 피어슨의 곱적률 상관(Pearson's product-moment correlation)은 두 변수의 선형 관계가 존재할 경우 그 관계가 얼마나 강한지 알 수 있는 값이며 두 변수가 연속형 양적 변수일 경우에 사용가능한 방법이다. 상관계수는 공분산으로 부터 유도되며, 이를 제곱하는 경우 단순 선형회귀의 결정계수와 같다. 그리고 상관계수의 값 범위는 -1 에서 1사이이며 부호가 양수인 경우 "양의 상관 관계" 음수인 경우 "음의 상관 관계" 라고 한다.

$$r = \frac{COV(X,Y)}{\sigma_x \times \sigma_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \times \sqrt{\sum (y_i - \bar{y})^2}}$$

- 검정통계량 t

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

- 가설
- 귀무가설(H0): 두 변수간 선형관계가 존재하지 않는다. (r = 0)
- 대립가설(H1): 두 변수간 선형관계가 존재한다. (r ≠ 0)

1. 상관분석

표본상관계수(sample correlation coefficient)

- **Spearman's Correlation**
- 스피어만 상관분석은 두 변수가 순서형 변수일 경우에 사용가능한 방법이며 두 변수가 정규성을 따르지 않는 경우에도 사용할 수 있는 비모수적 방법이다. 상관계수는 각 변수의 순위를 매긴 후 그 순위의 차를 활용하여 계산한다. 그리고 상관계수의 값 범위는 -1 에서 1사이 이며 부호가 양수인 경우 "양의 상관 관계" 음수인 경우 "음의 상관 관계" 라고 한다.

$$\rho = 1 - \frac{6\sum d_i^2}{n^3 - n}$$

$$t = \frac{\rho\sqrt{n-2}}{\sqrt{1-\rho^2}}$$

- 가설
- 귀무가설(H0): 두 변수간 선형관계가 존재하지 않는다. (rho = 0)
- 대립가설(H1): 두 변수간 선형관계가 존재한다. (rho ≠ 0)

표본상관계수(sample correlation coefficient)

- **Kendall Correlation**
- 상관분석은 두 변수가 순서형 변수일 경우에 사용가능한 방법이며 두 변수가 정규성을 따르지 않는 경우에도 사용할 수 있는 비모수적 방법이다. 그리고 상관계수의 값 범위는 -1 에서 1사이 이며 부호가 양수인 경우 "양의 상관 관계" 음수인 경우 "음의 상관 관계" 라고 한다.

$$\tau_A = \frac{n_c - n_d}{n_0}, \tau_B = \frac{n_c - n_d}{\sqrt{(n_0 - n_1)(n_0 - n_2)}}$$

$$n_0 = n(n-1)/2$$
$$n_1 = \sum t_i(t_i - 1)/2$$
$$n_2 = \sum u_j(u_j - 1)/2$$
$$n_c = Number\ of\ concordant\ pairs$$
$$n_d = Number\ of\ discordant\ pairs$$
$$t_i = Number\ of\ tied\ values\ in\ the\ i^th\ group\ of\ ties\ for\ the\ first\ quantity$$
$$u_j = Number\ of\ tied\ values\ in\ the\ j^th\ group\ of\ ties\ for\ the\ second\ quantity$$

$$\tau_C = \frac{2(n_c - n_d)}{n^2 \frac{m-1}{m}}$$

$$n_c = Number\ of\ concordant\ pairs$$
$$n_d = Number\ of\ discordant\ pairs$$
$$r = Number\ of\ rows$$
$$c = Number\ of\ columns$$
$$m = min(r, c)$$

표본상관계수(sample correlation coefficient)

- **Kendall Correlation**
- 검정통계량 z

$$z_A = \frac{3(n_c - n_d)}{\sqrt{n(n-1)(2n+5)/2}}, \; z_B = \frac{n_c - n_d}{\sqrt{v}}$$

$$\begin{aligned}
v &= (v_0 - v_t - v_u)/18 + v_1 + v_2 \\
v_0 &= n(n-1)(2n+5) \\
v_t &= \sum t_i(t_i - 1)(2t_i + 5) \\
v_u &= \sum u_j(u_j - 1)(2u_j + 5) \\
v_1 &= \sum t_i(t_i - 1) \sum u_j(u_j - 1)/2n(n-1) \\
v_2 &= \sum t_i(t_i - 1)(t_i - 2) \sum u_j(u_j - 1)(u_j - 2)/(9n(n-1)(n-2))
\end{aligned}$$

- 가설
- 귀무가설(H0): 두 변수간 선형관계가 존재하지 않는다. (tau = 0)
- 대립가설(H1): 두 변수간 선형관계가 존재한다. (tau ≠ 0)

표본상관계수(sample correlation coefficient)

- 상관분석의 유형

	피어슨	스피어만
개념	등간척도 이상으로 측정된 두 변수들의 상관관계측정 방식	서열척도인 두 변수들의 상관관계 측정방식
특징	연속형 변수, 정규성 가정 대부분 많이 사용	순서형 변수, 비모수적 방법 순위를 기준으로 상관관계 측정
상관계수	피어슨 γ(적률상관계수)	순위상관계수(ρ, 로우)

표본상관계수(sample correlation coefficient)

- 두 확률변수 X, Y로 부터 추출한 n개의 표본 쌍 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$에서 확률변수 X로 부터 추출한 표본 $x_1, x_2, \dots, x_n$의 평균을 $\bar{x}$, 표준편차를 s_x, 확률변수 Y로 부터 추출한 표본 $y_1, y_2, \dots, y_n$의 평균을 $\bar{y}$, 표준편차를 s_y라 하면, 표본공분산 $cov(x, y)$는 다음과 같이 두 표본의 편차의 곱을 모두 합하고 이를 자료의 개수(표본 쌍의 개수) – 1 로 나누어 구한다.

$$cov(x, y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

표본상관계수(sample correlation coefficient)

- 표본공분산을 각 표본의 표준편차의 곱으로 나누어 구한다.
- 표본을 통하여 상관계수를 추정하는 통계량

- $$r = \frac{cov(x,y)}{s_x s_y} = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{(n-1)s_x s_y} = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{(n-1)\sqrt{\frac{\sum_{i=1}^{n}(x_i-\bar{x})^2}{n-1}}\sqrt{\frac{\sum_{i=1}^{n}(y_i-\bar{y})^2}{n-1}}}$$

$$= \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i-\bar{y})^2}}$$

$$r_{XY} = \frac{S_{XY}}{\sqrt{S_{XX}S_{YY}}}$$

$$S_{XX} = \sum_{i=1}^{n}(X_i-\bar{X})^2 = \sum_{i=1}^{n}X_i^2 - \frac{(\sum_{i=1}^{n}X_i)^2}{n}$$

$$S_{YY} = \sum_{i=1}^{n}(Y_i-\bar{Y})^2 = \sum_{i=1}^{n}Y_i^2 - \frac{(\sum_{i=1}^{n}Y_i)^2}{n}$$

$$S_{XY} = \sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y}) = \sum_{i=1}^{n}X_iY_i - \frac{(\sum_{i=1}^{n}X_i)(\sum_{i=1}^{n}Y_i)}{n}$$

표본상관계수(sample correlation coefficient)

- 표본상관계수는 모상관계수와 동일한 성질을 가져
- -1 혹은 1에 가까울수록 강한 상관을 나타내고,
- 0에 가까이 갈수록 약한 상관을 나타낸다.
- 양수일 경우 두 변수의 값의 변화는 같은 방향으로 진행되고, 음수일 경우 값의 변화는 서로 반대가 된다.

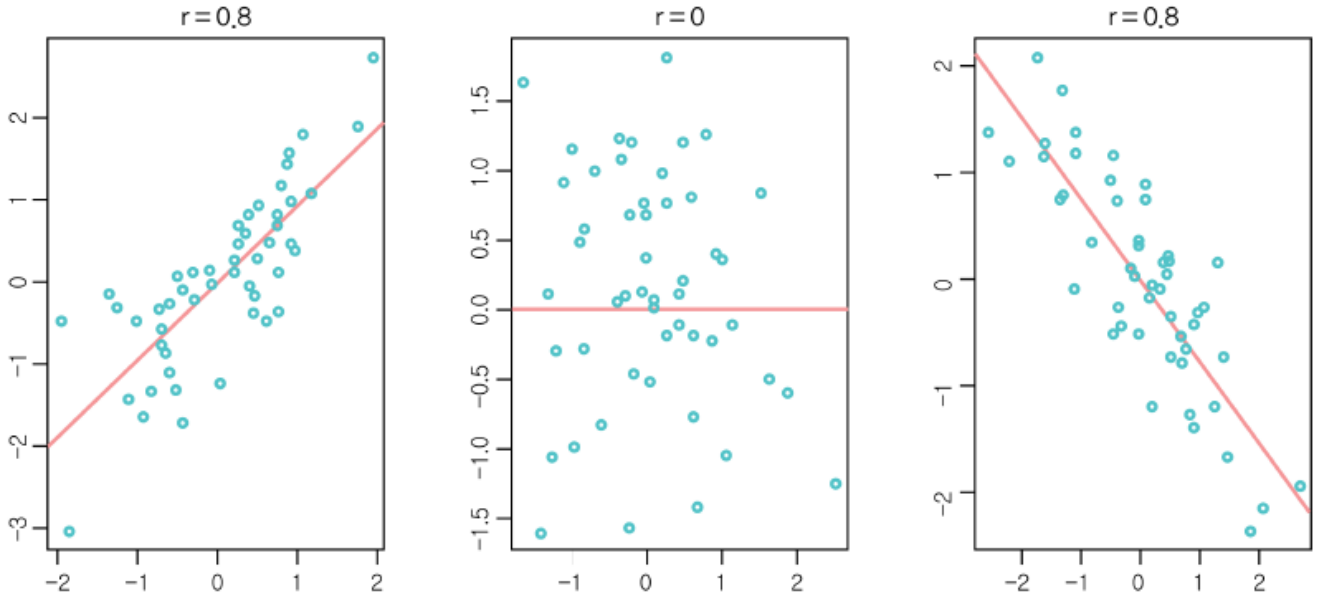

상관계수의 해석

구분	해석
0.0 ~ 0.1	거의 관계없음
0.1 ~ 0.2	약한 양의 상관관계
0.2 ~ 0.4	보통의 양의 상관관계
0.4 ~ 0.6	비교적 강한 양의 상관관계
0.6 ~ 0.8	강한 양의 상관관계
0.8 ~ 1.0	매우 강한 양의 상관관계

3. 상관계수

2차원 데이터의 시각화

- **산점행렬도**
- 여러 개의 양적 자료에 대한 산점도를 하나의 그래프로 보여주는 것을 산점행렬도 (scatter plot matrix)라고 한다. plot(x, y) 형태로 산점도를 작성하는 번거로운 일이다. 어떻게 산점행렬도를 작성하는지 학습해 보자.
- iris는 붓꽃이며 5개의 변수를 가지고 있다.

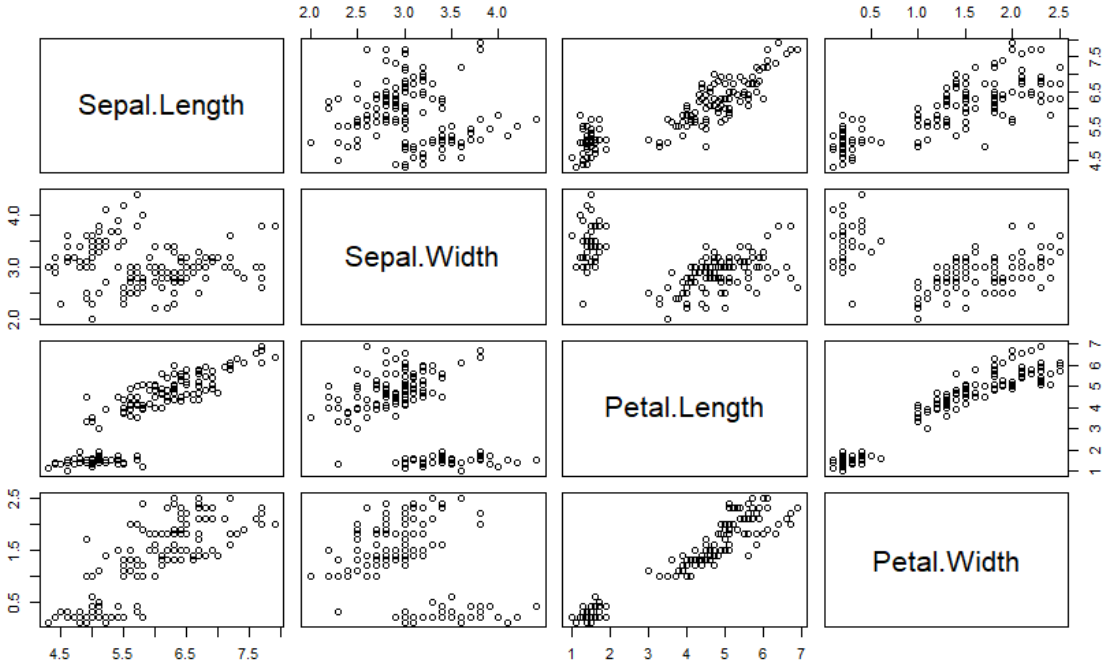

3. 상관계수

표본상관계수를 구하고 산점도 그리기

- **Ex-18.xlsx**

D	E
표본상관계수	0.736277

RANDBET... =CORREL(B2:B52,C2:C52)

	A	B	C
2	1	181	78
3	2	161	49
4	3	170	52
5	4	160	53
6	5	158	50
7	6	168	57
8	7	162	53
9	8	179	54
10	9	183	71
11	10	178	73
12	11	171	55
13	12	177	73
14	13	163	51
15	14	158	53
16	15	160	65

함수 인수

CORREL

Array1 B2:B52 = {181;161;170;160;158;168;162;17...

Array2 C2:C52 = {78;49;52;53;50;57;53;54;71;73;55...

= 0.736276506

두 데이터 집합 사이의 상관 계수를 구합니다.

Array2 은(는) 둘째 값들의 셀 범위입니다. 범위는 숫자, 이름, 숫자가 들어 있는 배열이나 참조가 될 수 있습니다.

수식 결과= 0.736276506

도움말(H) 확인 취소

3. 상관계수

표본상관계수를 구하고 산점도 그리기

- **Ex-18.xlsx**

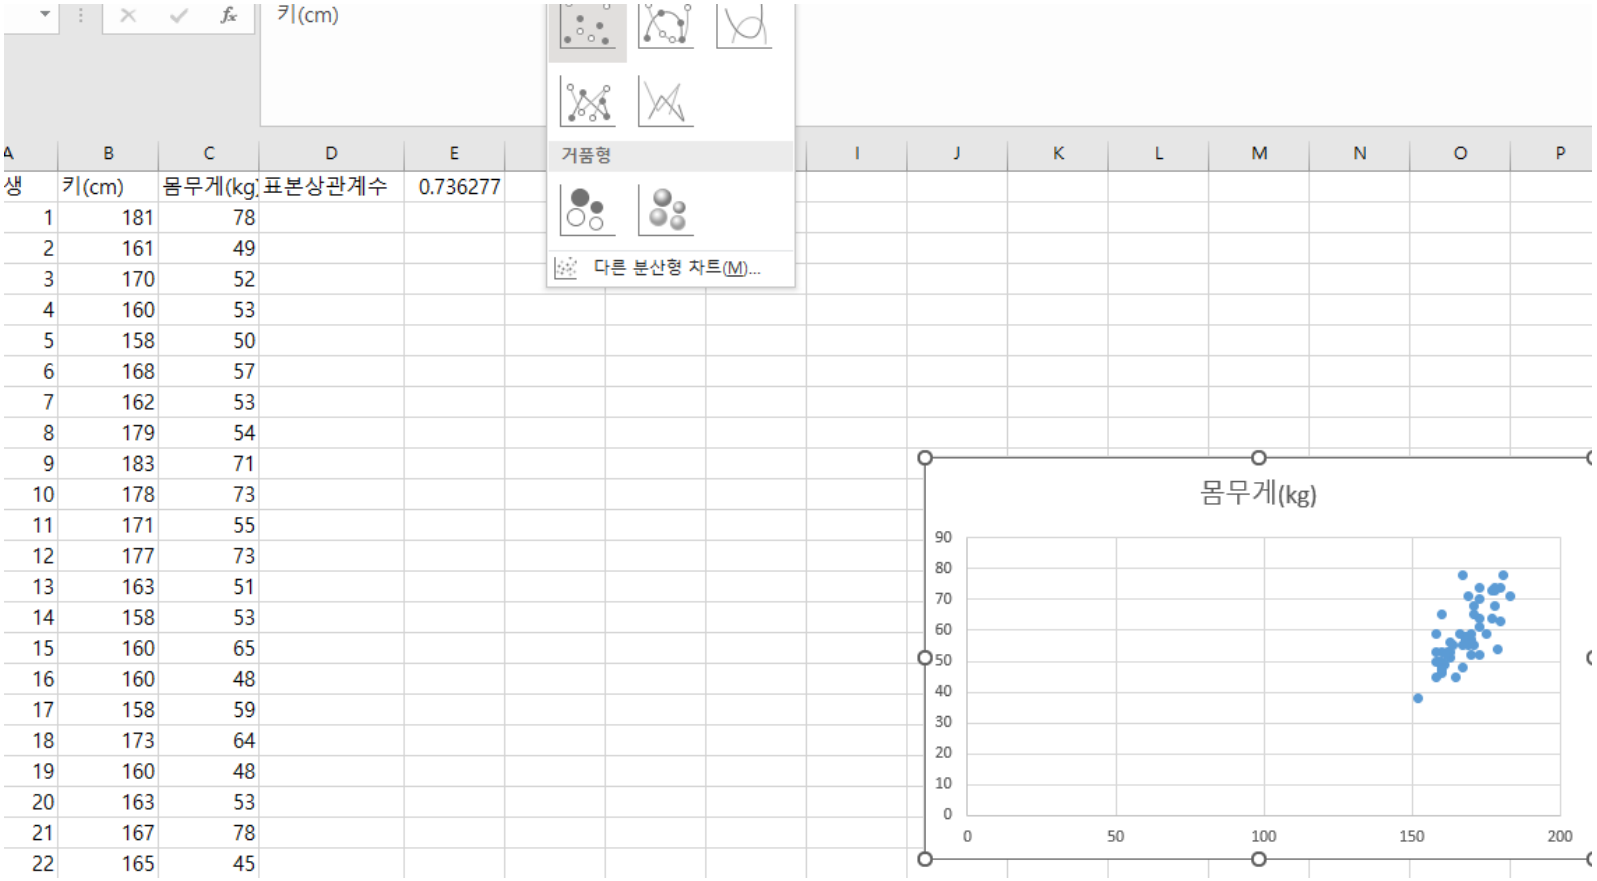

생	키(cm)	몸무게(kg)	표본상관계수	0.736277
1	181	78		
2	161	49		
3	170	52		
4	160	53		
5	158	50		
6	168	57		
7	162	53		
8	179	54		
9	183	71		
10	178	73		
11	171	55		
12	177	73		
13	163	51		
14	158	53		
15	160	65		
16	160	48		
17	158	59		
18	173	64		
19	160	48		
20	163	53		
21	167	78		
22	165	45		

3. 상관계수

표본상관계수를 구하고 산점도 그리기

- X 축서식

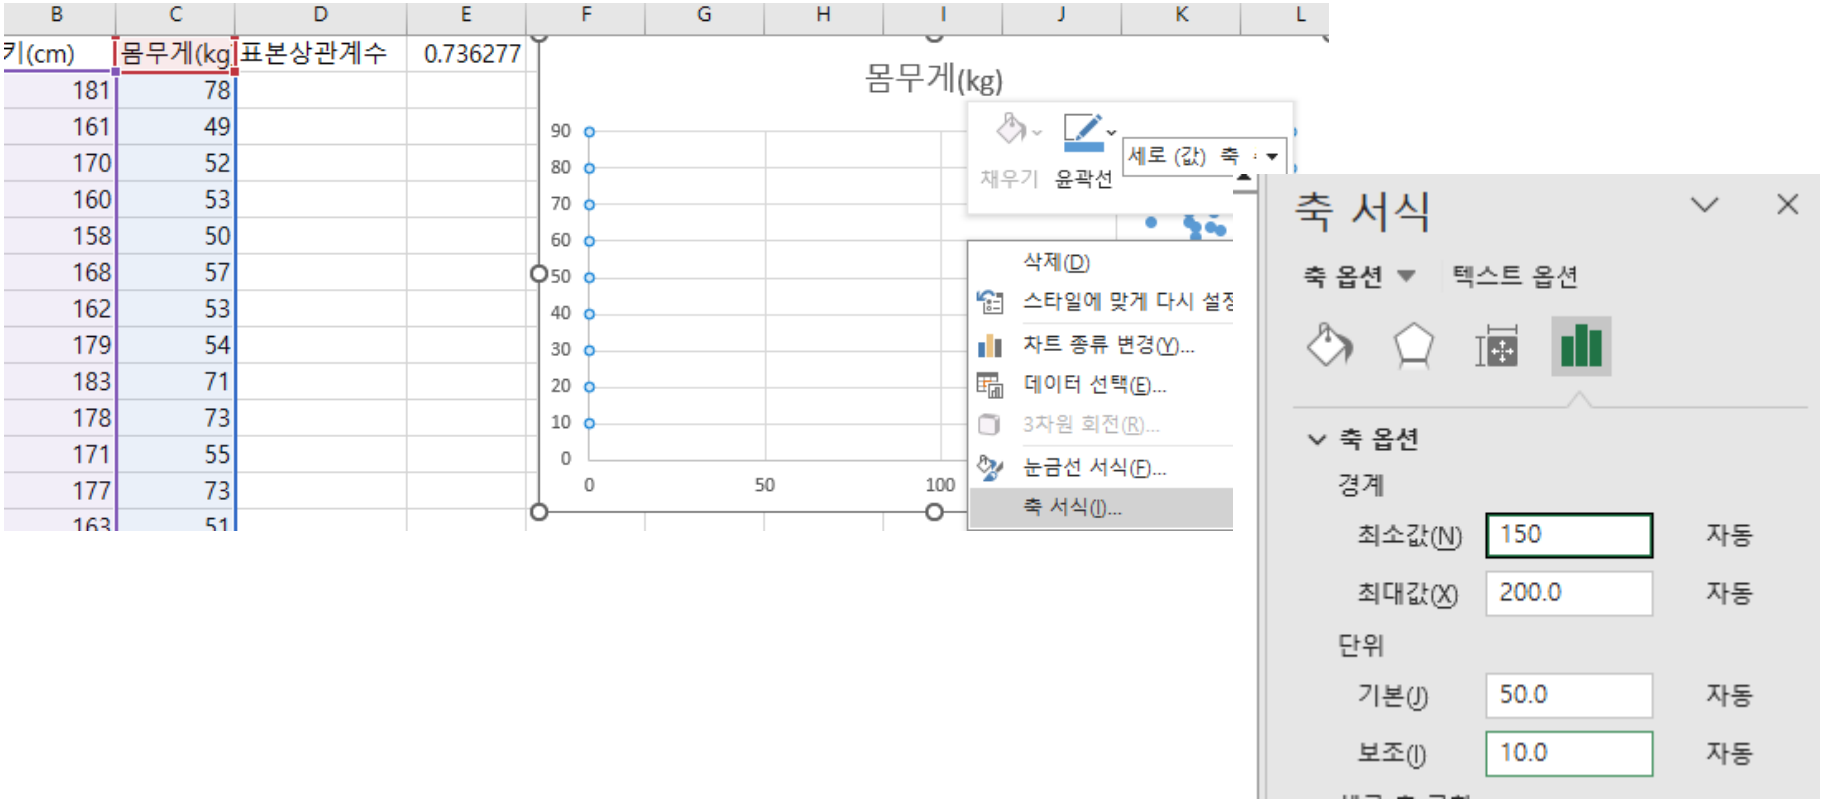

3. 상관계수

표본상관계수를 구하고 산점도 그리기

- Y 축서식

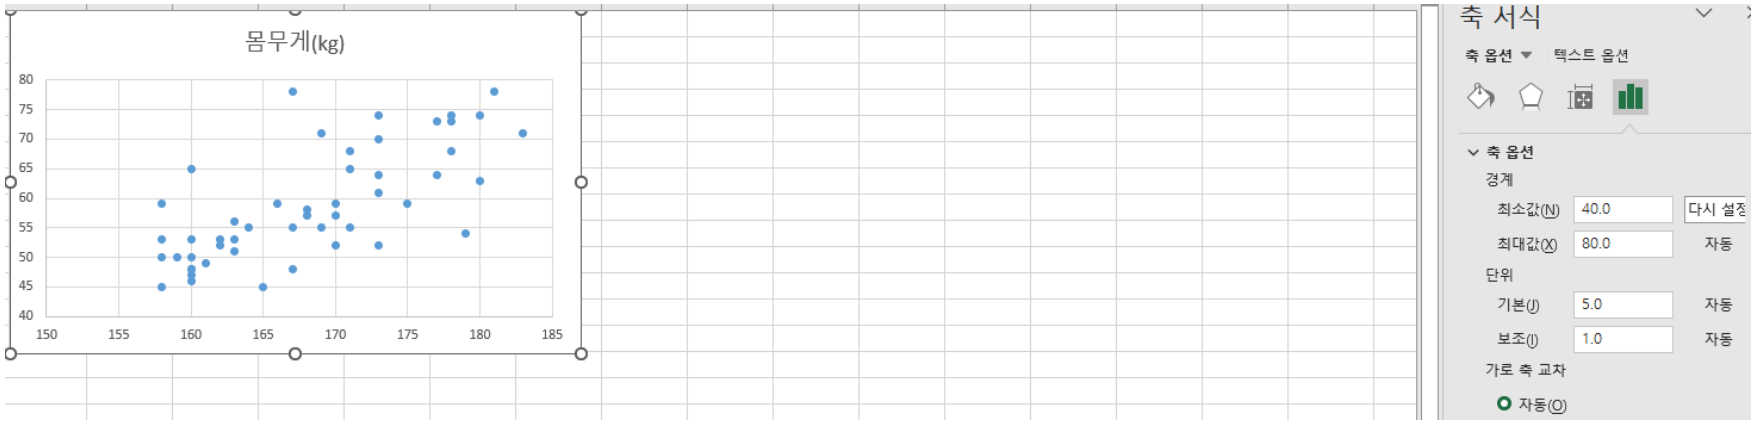

『4장』 통계와 데이터 분석

상관분석

회귀분석

Syllabus

학습목표

- 이 워크샵에서는 회귀분석에 대해 알 수 있습니다.

눈높이 체크

- 회귀분석을 알고 계신가요?

1. 회귀분석

회귀분석의 개요

- 19 세 기 영국의 우생학자 프 랜 시 스 갤 턴 (Francis Galton,1822~1911)은 부모의 키가 큰 자식들의 키가 점점 더 커지지 않고 다시 평균 키로 회귀하는 경향을 발견하였는데, 이를 통계학에서는 '평균으로의 회귀'라고 하며 회귀분석의 '회귀'란 용어는 여기서 파생됨
- 회귀분석의 정의
  - 하나나 그 이상의 독립변수들이 종속변수에 미치는 영향을 추정할 수 있는 통계기법
  - 변수들 사이의 인과관계를 밝히고 모형을 적합하여 관심 있는 변수를 예측하거나 추론하기 위한 분석 방법
  - 독립변수의 개수가 하나 -> 단순 선형 회귀분석으로 분석
  - 독립변수의 개수가 두 개 이상 -> 다중 선형 회귀분석으로 분석할 수 있다

1. 회귀분석

회귀분석의 개요

● 회귀분석의 변수

변수	종류
영향받는 변수(y)	반응변수, 종속변수, 결과변수
영향주는 변수(x)	설명변수, 독립변수, 예측변수

● 회귀분석의 4단계

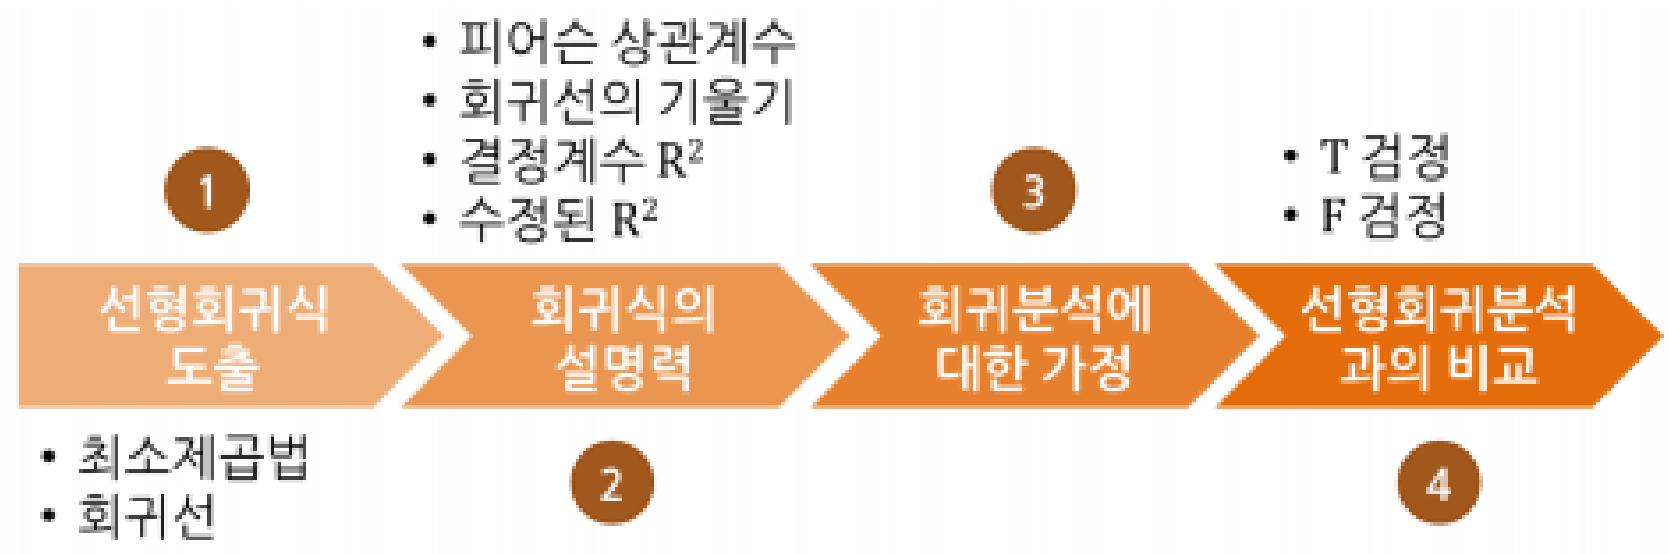

1. 회귀분석

회귀분석의 개요

- 그래프를 활용한 선형 회귀 분석의 가정 검토
- 선형성: 선형 회귀모형에서는 설명변수 x와 반응 변수 y가 선형 관계에 있음을 전재되어야 한다.
- 등분산성
  - 등분산성을 만족: 설명변수 x에 대한 잔차의 산점도를 그렸을 때 설명변수 x 값에 관계없이 잔차들의 변동성이 일정한 형태를 보임
  - 등분산성을 만족 x: 설명변수 x가 커질수록 잔차의 분사가 줄어드는 이분산 형태 / 2차항 설명변수가 필요 / 새로운 설명변수가 필요

- 정규성: Q-Q Plot을 출력했을 때, 잔차가 대각선 방향의 직선의 형태를 지니고 있으면 잔차는 정규분포를 따른다고 할 수 있다.
- 가정에 대한 검증
- 단순 선형 회귀분석: 입력 변수와 출력 변수 간의 선형성을 점검하기 위해 산점도를 확인
- 다중 선형 회귀분석: 선형 회귀분석의 가정인 선형성, 등분산성, 독립성, 정상성 이 모두 만족하는지 확인해야 한다.

1. 회귀분석

단순 선형 회귀분석

- 하나의 독립변수가 종속변수에 미치는 영향을 추정할 수 있는 통계기법

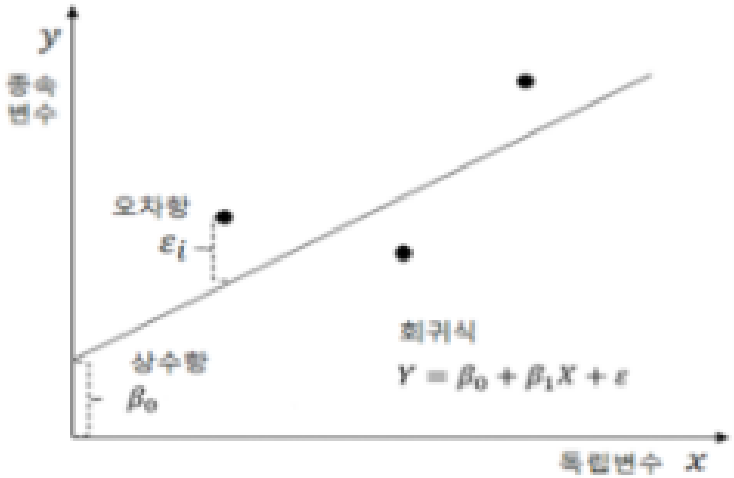

$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

y_i: i번째 종속변수 값

x_i: i번째 독립변수 값

β_0: 선형 회귀식의 절편

β_1: 선형 회귀식의 기울기

ε_i: 오차항, 독립적이면 $N(0,\sigma^2)$의 분포를 이룬다.

단순 선형 회귀분석

- 회귀분석에서의 검토사항

1) 회귀 계수들이 유의미한가?: 해당 계수의 t 통계량의 p-값이 0.05보다 작으면 해당 회귀계수가 통계적으로 유의미하다고 볼 수 있다.
2) 모형은 얼마나 설명력을 갖는가?: 결정계수를 확인한다. 결정계수는 0~1 값을 가지며, 높은 값을 가질수록 추정된 회귀식의 설명력을 높인다.
3) 모형이 데이터를 잘 적합하고 있는가?: 잔차를 그래프로 그리고 회귀 진단을 한다.

- 회귀계수의 추정(최소 제곱 법, 최소 자승 법)

• 측정값을 기초로 하여 적당한 제곱합을 만들고, 그것을 최소로 하는 값을 구하여 측정값을 처리하는 방법으로 잔차 제곱이 가장 작은 선을 구하는 것을 의미

$$\hat{B}_0 = \bar{y} - \hat{B}_1\bar{x}, \qquad \hat{B}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

회귀계수 추정식

단순 선형 회귀분석

● 회귀분석의 검정

1) 회귀계수의 검정

- 회귀계수 β_1이 0이면 입력 변수 x와 출력 변수 y사이에는 아무런 인과관계가 없다.
- 회귀계수 β_1이 0이면 적합한 추정식은 아무 의미가 없게 된다.(귀무가설:$\beta_1=0$, 대립 가설:$\beta_1 \neq 0$)

2) 결정계수

- 전체 제곱합(SST): 회귀식과 실제값의 차이를 제곱한 값(SST=SSR+SSE)
- 회귀 제곱합(SSR): 회귀식과 평균값의 차이, 모형이 설명하는 부분
- 오차 제곱합(SSE): 편차의 제곱합. 모형이 설명하지 부분

1. 회귀분석

단순 선형 회귀분석

- 회귀분석의 검정
- 결정계수(R^2)는 전체 제곱합에서 회귀 제곱 합의 비율(SSR/SST), $0 \le R^2 \le 1$, 1에 가까울수록 설명력 높음
- 결정계수(R^2)는 전체 데이터의 회귀모형이 설명할 수 있는 설명력을 의미(단순 회귀분석에서 결정계수는 상관계수 r의 제곱을 의미)

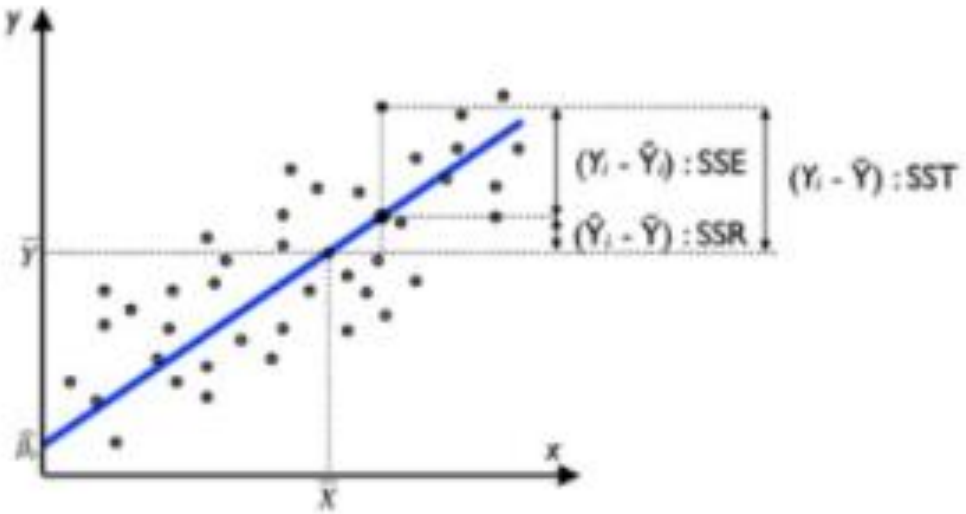

$$SST = \sum_{i=1}^{n} (Y_i - \bar{Y})^2$$

$$SSR = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2$$

$$SSE = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2$$

단순 선형 회귀분석

- 회귀분석의 검정

3) 회귀 직선의 적합도 검토

- 결정계수(R^2)를 통해 추정된 회귀 식이 얼마나 타당한지 검토(결정계수(R^2)가 1에 가까울수록 회귀모형임)
- 독립변수가 종속변수 변동의 몇 %를 설명하는지 나타내는지 표
- 다변량 회귀분석에서는 독립변수의 수가 많아지면 결정계수(R^2)가 높아지므로 독립변수가 유의하든, 유의하지 않든 독립변수의 수가 많아지면 결정계수가 높아지는 단점이 있다.
- 이러한 결정계수의 단점을 보완하기 위해 수정된 결정계수(adjusted R^2)를 활용한다. 수정된 결정계수는 결정계수보다 작은 값으로 산출된다.

1. 회귀분석

단순 선형 회귀분석

- 오차와 잔차의 차이
- 오차: 모집단에서 실제값이 회귀선과 비교해 볼 때 나타나는 차이 (정확치와 관측치 차이)
- 잔차: 표본에서 나온 관측값이 회귀선과 비교해볼 때 나타나는 차이
- 회귀모형에서 오차항은 측정할 수 없으므로 잔차를 오차항의 관찰값으로 해석하여 오차항에 대한 가정들의 성립 여부를 조사함

1. 회귀분석

다중 선형 회귀분석

- **다중회귀식** $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \varepsilon$

- **모형의 통계적 유의성 (F 통계량 확인)**
  - **유의 수준 5% 하에 F 통계량의 p-값이 0.05보다 작으면 추정된 회귀식은 통계적으로 유의하다고 볼 수 있다.**
  - **F통계량이 크면 p-value가 0.05보다 작아지고, 이렇게 되면 귀무가설을 기각한다. 즉 모형이 유의하다고 결론**

	제곱합	자유도	제곱평균	F-총계량
회차	회차제곱합(SSR)	k	MSR=SSR/k	F=MSR/MSE
오차	오차제곱합(SSE)	n-k+1	MSE=SSE(n-k+1)	
계	전체제곱합(SST)	n-1		

1. 회귀분석

다중 선형 회귀분석

- 회귀계수의 유의성 (t 통계량을 통해 확인)
  - 모든 회귀계수의 유의성이 통계적으로 검증되어야 선택된 변수들의 조합으로 모형을 활용할 수 있다.
- 모형의 설명력
  - 결정계수(R^2)나 수정된 결정계수(R^2)를 확인한다.
- 모형의 적합성
  - 모형이 데이터를 적합하고 있는지 잔차와 종속변수의 산점도를 확인
- 데이터가 전제하는 가정을 만족시키는가?
  - 선형성, 독립성, 등분산성, 빙상관성, 정상성
- 다중공선성
  - 다중회귀분석에서 설명변수들 사이에 선형관계가 존재하면 회귀계수의 정확한 추정이 곤란하다.

1. 회귀분석

다중 선형 회귀분석

- 다중공선성 검사방법

1) 분산 팽창 요인: 4보다 크면 다중공선성이 존재한다고 볼 수 있고, 10보다 크면 심각한 문제가 있는 것으로 해석
2) 상태 지수: 10 이상이면 문제가 있다고 보고, 30보다 크면 심각한 문제가 있다고 해석할 수 있다. 다중 선형 회귀분석에서 다중공선성 문제가 발생하면 문제가 있는 변수를 제거하거나 주성분 회귀, 능형회귀 모형을 적용하여 문제를 해결

회귀분석의 종류

종류	모형
단순회귀	독립변수가 1개이며 종속변수와의 관계가 직선
다중회귀	독립변수가 k개이며 종속변수와의 관계가 선형(1차함수)
로지스틱회귀	종속변수가 범주형(2진변수)인 경우에 적용되며, 단순 로지스틱 회귀 및 다중, 다항 로지스틱 회귀로 확장할 수 있음
다항회귀	독립변수와 종속변수와의 관계가 1차함수 이상인 관계 (단 k=1이면 2차함수 이상)
곡선회귀	독립변수가 1개이며 종속변수와의 관계가 곡선
비선형회귀	회귀식의 모양이 미지의 모수들의 선형관계로 이뤄져 있지 않는 모형

회귀 분석 계산하기

예제 파일 Ex-16.xlsx

회귀 분석 계산: 데이터로부터 정수인 회귀절편 a와 회귀계수 b를 구하는 계산
엑셀 함수: 회귀계수를 구하는 'SLOPE'와 회귀절편을 구하는 'INTERCEPT' 또는 [데이터 분석] 도구를 사용

01 [데이터] - [분석] 그룹 - [데이터 분석] - [통계 데이터 분석] - [분석도구] '회귀 분석'을 선택하고 [확인] 클릭

02 [회귀 분석] 대화상자에서 [Y축 입력 범위]에 '1인당 국민 의료비' 데이터 범위, [X축 입력 범위]에 '생활습관병 에 의한 사망자 수' 데이터 범위를 지정하고 [확인] 클릭

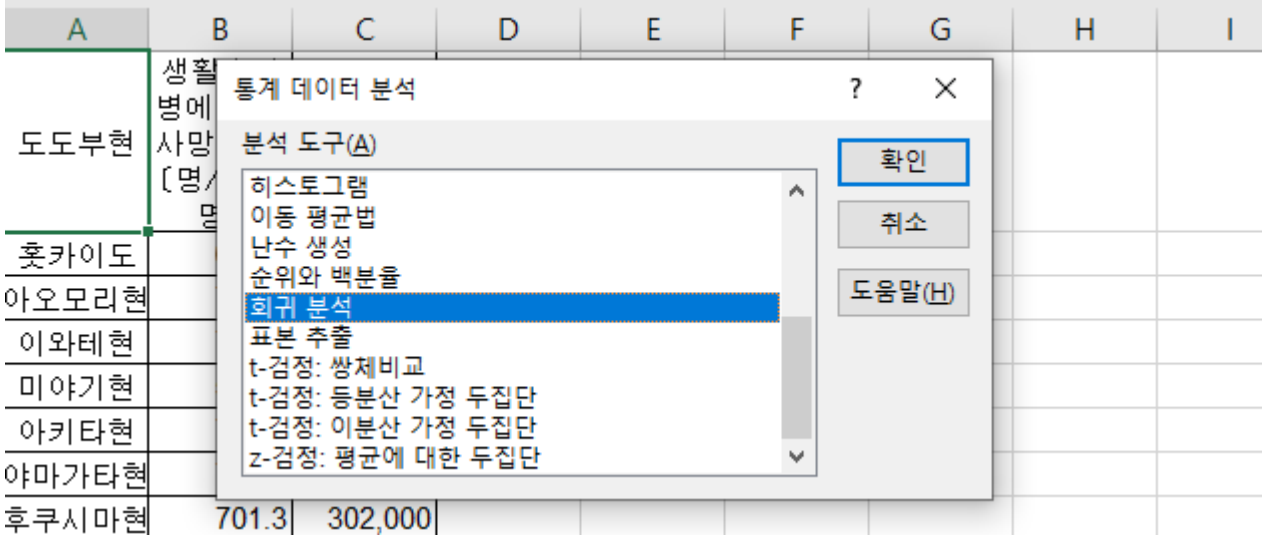

회귀 분석 계산하기

03 다음과 같이 출력 결과 생성

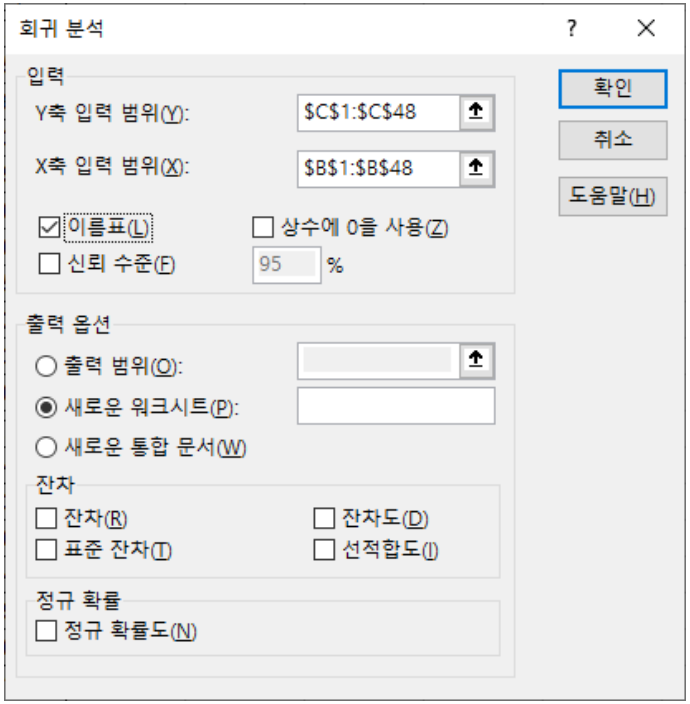

요약 출력

회귀분석 통계량	
다중 상관	0.532659
결정계수	0.283726
조정된 결	0.267808
표준 오차	30681.57
관측수	47

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	1	1.68E+10	1.68E+10	17.82508	0.000116
잔차	45	4.24E+10	9.41E+08		
계	46	5.91E+10			

	계수	표준 오차	t 통계량	P-값	하위 95%	상위 95%	하위 95.0%	상위 95.0%
Y 절편	178536	32690.57	5.461393	1.95E-06	112693.8	244378.2	112693.8	244378.2
생활습관병에 의한 사망자 수 〔명/10만명〕	223.2454	52.877	4.221976	0.000116	116.7457	329.7452	116.7457	329.7452

$$y = 178{,}536.01 + 223.25x$$

다중 회귀 모델

예제 파일 Ex-16.xlsx

'뇌혈관질환'을 '생활습관병'에 더한 다중 회귀 모델 구하기

01 다중 회귀 모델의 회귀절편과 2가지 회귀계수는직접해보기 3과 같이 [데이터 분석]의 [회귀 분석] 사용

02 다른 점은 [X축 입력 범위]에 '생활습관병'과 '뇌혈관질환'에 의한 사망자 수 데이터 범위를 함께 지정

[Y축 입력 범위]에는 동일하게 '1인당 국민 의료비' 데이터를 지정

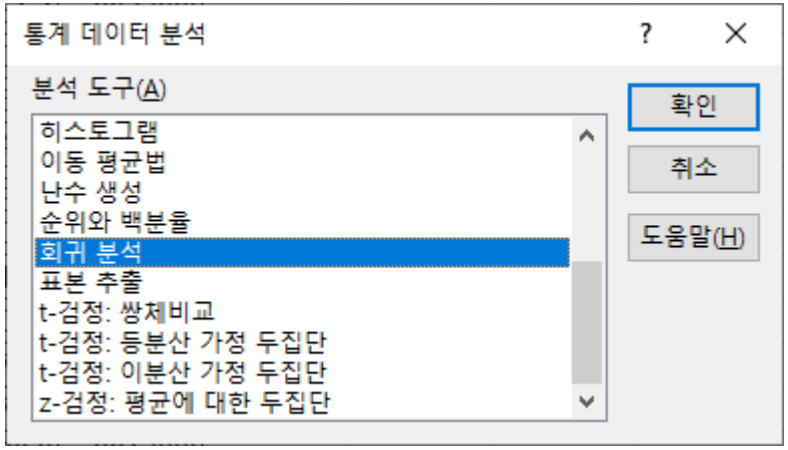

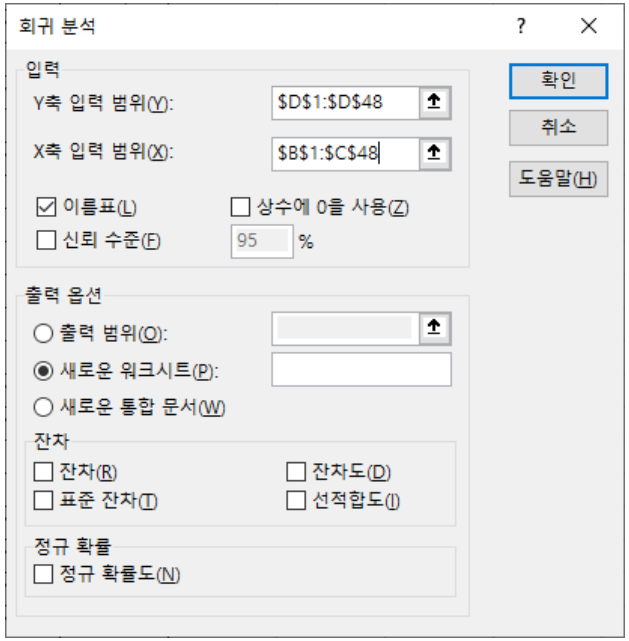

다중 회귀 모델

결과

요약 출력

회귀분석 통계량	
다중 상관계수	0.69
결정계수	0.47
조정된 결정계수	0.45
표준 오차	26605.70
관측수	47.00

분산 분석

	자유도	제곱합	제곱 평균	F 비	유의한 F
회귀	2	2.8E+10	1.4E+10	19.77426	7.47E-07
잔차	44	3.11E+10	7.08E+08		
계	46	5.91E+10			

	계수	표준 오차	t 통계량	P-값	하위 95%	상위 95%	하위 95.0
Y 절편	113836.52	32677.31	3.483657	0.001131	47979.73	179693.3	47979.
생활습관병에 의한 사망자 수 〔명/10만 명〕	566.37	97.64	5.80	0.00	369.59	763.15	369.5
뇌혈관질환에 의한 사망자 수 〔명/10만 명〕	-1405.21	353.03	-3.98	0.00	-2116.69	-693.72	-2116.6

회귀분석 통계량	
다중 상관계수	0.69
결정계수	0.47
조정된 결정계수	0.45
표준 오차	26605.70
관측수	47.00

	계수
Y 절편	113836.52
생활습관병에 의한 사망자 수 〔명/10만 명〕	566.37
뇌혈관질환에 의한 사망자 수 〔명/10만 명〕	-1405.21

1. 회귀분석

다중 회귀 모델

1인당 국민 의료비: 변수 y,
생활습관병에 의한 사망자 수: 변수 x1, ‘
뇌혈관질환에 의한 사망자 수: 변수 x2
회귀 모델 y = 113,836.52+566.37x1 - 1,405.21x2

생활습관병에 의한 사망자 수의 증가가 국민 의료비의 상승 요인으로 작용하는데 비해, 뇌혈관질환에 의한 사망자 수의 증가는 국민 의료비의 하락 요인으로 작용하고 있다는 것을 의미

결정계수 R2은 0.47이므로 생활습관병에 의한 사망자만 넣은 단순 회귀 모델에 비해 개선되었음

1. 회귀분석

최적 회귀 방식

- 종속변수에 유의미한 영향을 미칠 것으로 생각되는 독립변수를 찾는 방법
- 보통 모델의 성능을 향상하기 위해 사용

● 최적화 회귀 방정식의 선택

1) 설명 변수 선택

- 필요한 변수만 상황에 따라 타협을 통해 선택
- y에 영향을 미칠 수 있는 모든 설명변수 x들은 y의 값을 예측하는데 참여한다.
- 데이터에 설명변수 x들의 수가 많아지면 관리하는데 많은 노력이 요구 -> 가능한 범위 내에서 적은 수의 설명변수 포함

2) 모형 선택

- 분석 데이터에 가장 잘 맞는 모형을 찾아내는 방법
- 모든 가능한 조합의 회귀 분석: 모든 가능한 독립변수들의 조합에 대한 회귀모형을 생성 & 가장 적합한 회귀모형 선택

최적 회귀 방식

● 최적화 회귀 방정식의 선택

3) 단계적 변수 선택

종류	내용
전진선택법	절편만 있는 상수모형으로부터 시작해 중요하다고 생각되는 설명변수로부터 차례로 모형에 추가 - 장점: 이해하기 쉽고, 변수의 개수가 많은 경우에도 사용 가능 - 단점: 변수값의 작은 변동에도 그 결과가 크게 달라져 안전성이 부족
후진제거법	독립변수 후보 모두 포함한 모형에서 출발해 가장 적은 영향을 주는 변수부터 하나씩 제거하면서 더이상 제거할 변수가 없을 때의 모형을 선택함 - 장점: 전체 변수들의 정보를 이용할 수 있음 - 단점: 변수의 개수가 많은 경우 사용하기 어려움
단계선택법	전진석택법에 의해 변수를 추가하면서 새롭게 추가된 변수에 기인해 기존 변수의 중요도가 약화되면 해당 변수를 제거하는 등 단계별로 추가 또는 제거되는 변수의 여부를 검토해 더 이상 없을 때 중단한다.

최적 회귀 방식

- 벌점화된 선택 기준
- 모형의 복잡도에 벌점을 주는 방법. AIC와 BIC방법이 주로 사용
- 방법: AIC, BIC 방법
- 설명
- 모든 후보 모형들에 대해 AIC 또는 BIC를 계산하고 그 값을 최소가 되는 모형을 선택
- 모형 선택의 일치성: 자료가 늘어날 때 참인 모형이 주어진 모형 선택 기준의 최솟값을 갖게 되는 성질
- 이론적으로 AIC에 대해 일치성이 성립되지 않지만 BIC는 주요 분포에서 이러한 성질이 성립
- AIC를 활용하는 방법이 보편화하는 방법 그 밖의 선택 기준으로 RIC, CIC가 있다.

회귀계수

- t 검정

  - 귀무가설 : $\beta_1 = 0$
  - 대립가설 : $\beta_1 \neq 0$

검정통계량은 $t = \dfrac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 C_1}}$ 이고, 귀무가설은 $\beta_1 = 0$이므로

$t = \dfrac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2 C_1}}$ 을 계산

2. 단순회귀모형

회귀계수

- t 검정

• 귀무가설 : $\beta_0 = 0$

• 대립가설 : $\beta_0 \neq 0$

검정통계량은 $t = \dfrac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 C_0}}$ 이고, 귀무가설은 $\beta_0 = 0$이므로

$t = \dfrac{\hat{\beta}_0}{\sqrt{\hat{\sigma}^2 C_0}}$ 을 계산

3. 다중회귀모형

다중회귀모형 개념

- 선형 회귀분석은 설명변수와 목적변수(혹은 반응변수) 간의 관계가 선형인 회귀분석을 말하며, 설명변수(혹은 독립변수)가 한 개인 경우 단순선형 회귀분석이라고 하며, 설명변수가 2개 이상이면 다중회귀분석이라고 부른다.
- 독립변수가 한 개인 경우 2차원 그래프로 관계를 확인하는 것이 유용하다. 그러나 독립변수가 2개 이상이 되면, 3차원 공간상에서 2차 평면으로 회귀적합이 표현되며, 독립변수가 3개를 넘어가면 4차원 이상이 되어 시각적으로 파악하기가 어려워진다. 하지만 일반적으로 특정 현상을 설명하는 데 있어서 목표변수 Y의 변화가 하나의 독립변수로 잘 설명되는 경우는 거의 없다고 할 수 있다. 따라서 적절한 독립변수들을 선정하여 이들의 함수로서 목표변수를 설명하고자 하는 다중회귀분석을 일반적으로 시행하게 된다.
- 이러한 다중회귀분석의 모형은 아래와 같이 표현할 수 있다.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \epsilon$$

$$Y = X\beta + \epsilon$$

3. 다중회귀모형

가변수

- 질적변수를 변환하여 양적변수와 동일하게 취급할 수 있게 하는 기법
- 0과 1을 취하는 2진 변수
- 변환하고 싶은 질적변수의 카테고리 수에서 하나를 줄인 수만큼 필요
- 통학 방법 '버스' '자전거' '도보'인 카테고리 수는 3이므로

가변수는 2개 $x_{도보}, x_{자전거}$

도보 $(x_{도보}=1, x_{자전거}=0)$, 자전거 $(x_{도보}=0, x_{자전거}=1)$,

버스 $(x_{도보}=0, x_{자전거}=0)$

회귀모형 $Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i도보} + \beta_4 x_{i자전거} + \epsilon_i$

4. 모형의 선택

과적합

- 적합이 좋다는 것은 모형이 주변에 있는 데이터에 어느 정도 들어 맞는다. 회귀직선이 데이터에 완전하게 들어맞고 잔차가 작으면 그 모형은 좋은 모형이라고 할 수 있다. 모르는 데이터의 설명변수라도 모형이 반응변수를 정확하게 예측할 수 있다면 그것은 좋은 모형이라고 할 수 있다.
- 적합이 좋다는 것은 설명변수를 증가시켜 가는 것만으로 간단하게 달성된다. 그러나 이렇게 만든 모형은 일반적으로 예측 정확도가 떨어진다. 이것을 과적합(overfitting)이라고 하는데, 복잡한 모형은 표현력이 너무 높아 나머지 주변 데이터에 지나치게 적합되어 일반적인 예측성을 잃게 된다. 따라서 모형을 고를 때 적합도가 좋은 것보다 예측 정확도가 좋은 것을 고르게 된다.

4. 모형의 선택

결정계수

- 모형의 데이터에 대한 적합도를 나타내는 기본적인 지표

$$R^2 = \frac{\text{회귀변동}}{\text{총변동}} = 1 - \frac{\text{잔차변동}}{\text{총변동}}$$

- 총변동 $\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$ = 회귀변동 + 잔차변동
- 회귀변동 $\sum_{i=1}^{n}(y_i - \bar{y})^2$
- 잔차변동 $\sum_{i=1}^{n}\hat{\epsilon}_i^2$

4. 모형의 선택

조정결정계수

- 설명변수를 추가했을 때, 해당 설명변수에 어느 정도 이상의 설명력이 없는 경우 결정계수의 값이 증가하지 않도록 조정하는 결정계수

$\overline{R}^2$ Adj. R-squred

- 자유도를 고려하므로 '자유도조정 결정계수'라고도 부름

$$\overline{R}^2 = 1 - \frac{\text{잔차변동}/n-p-1}{\text{총변동}/n-1}$$

최대로그우도와 AIC

- **우도(likelihood): 어떤 관측값을 얻을 확률**
- 동전의 확률함수 f(x) 얻은 관측값 x_1, x_2, x_3, x_4, x_5

$$L = \prod_{i=1}^{5} f(x_i) = 0.3^2 0.7^3 \simeq 0.031$$

- 동전의 앞면이 나올 확률 p를 널지 못하는 상황에서 결과 [0, 1, 0, 0, 1]

$$L = \prod_{i=1}^{5} f(x_i) = p^2 (1-p)^3$$

- 우도함수 L(p): 우도 L은 p에 대한 함수로 표현우도는 확률의 곱으로, 곱하면 곱할수록 0에 가까워져 다루기 어려움
- 우도에 로그를 취한 로그우도를 대신 사용

$$\log L = \sum_{i=1} \log f(x_i)$$

4. 모형의 선택

최대로그우도와 AIC

- **AIC**
- 로그우도와 같은 적합도는 의미 없는 설명변수를 늘리면 증가하므로 성능이 나쁜 모형이 선택
- 모형의 복잡도(설명변수의 수)와 데이터에 대한 균형을 잡는 지표 필요
- 일반적인 성능도 고려한 지표

$$AIC = -2 \times \text{최대로그우도} + 2 \times \text{회귀계수의 수}$$

- **AIC는 값이 작을수록 모형의 예측 정확도가 좋음**
  - 기말고사 ~ 쪽지 시험 : 156.7
  - 기말고사 ~ 쪽지 시험 + 수면 시간 : 153.0
  - 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 154.7

4. 모형의 선택

최대로그우도와 AIC

- **베이지안 정보 기준**
- **회귀계수의 수에 대해 표본 크기 n에 대해서도 페널티 부가**

$$BIC = -2 \times \text{최대로그우도} + \log n \times \text{회귀계수의 수}$$

- **값이 작을수록 모형의 예측 정확도가 좋음**

  - 기말고사 ~ 쪽지 시험 : 158.6
  - 기말고사 ~ 쪽지 시험 + 수면 시간 : 156.0
  - 기말고사 ~ 쪽지 시험 + 수면 시간 + 통학 방법 : 159.7

4. 모형의 선택

모형의 타당성

- 회귀분석에 관해서 세운 '오차항 ϵ_i는 서로 독립이고 $N(0, \sigma^2)$ 을 따른다는 가정을 만족하고 있는지의 여부를 체크하는 것
- 잔차 ϵ_i

정규성 검정

- 오차항 ϵ_i 가 $N(0, \sigma^2)$ 을 따른다는 가정이 타당한지를 알아보기 위해, 잔차 ϵ_i가 정규분포를 따르고 있는지를 확인하는 정규성 검정을 수행

• 귀무가설 : 잔차항은 정규분포를 따릅니다.

• 대립가설 : 잔차항은 정규분포를 따르지 않습니다.

- statsmodels의 정규성 검정은 Omnibus와 Jarque-Bera(JB)

4. 모형의 선택

더빈-왓슨비

- 다른 오차항이 서로 무상관인지 여부를 체크하는 지표
- 0에 가까우면 양의 상관, 4에 가까우면 음의 상관, 2 전후의 값이면 무상관

$$\frac{\sum_{i=2}^{n}(\hat{\epsilon}_i - \hat{\epsilon}_{i-1})^2}{\sum_{i=1}^{n}\hat{\epsilon}_i^2}$$

4. 모형의 선택

다중공선성

- 조건수의 값이 크면 다중공선성과 설명변수에 강한 상관
- 다중공선성이 크면 회귀계수의 분산이 커져 모형의 예측 결과가 나빠짐
- 쪽지 시험의 결과를 2배로 한 중간고사 변수 추가
- 쪽지 시험과 중간고사의 상관관계는 1, 다중공선성이 큼

- 사례

- 조건수가 1.22e+17
- 다중공선성이 생기면 조건수는 매우 큰 값이 됨
- 조건수가 꽤 큰 값이면 다중공선성을 의심
- 설명변수 중에서 한 쪽 변수를 모형에서 제외

『4장』 통계와 데이터 분석

상관분석
회귀분석
데이터 분석 퀴즈

1. 퀴즈1

자료 준비

dataanalytics.xlsx

분석 도구 추가

dataanalyt데이터 분석 메뉴 추가는 파일 → 옵션 → 추가기능 → 관리 메뉴에서 이동 버튼을 클릭한다.

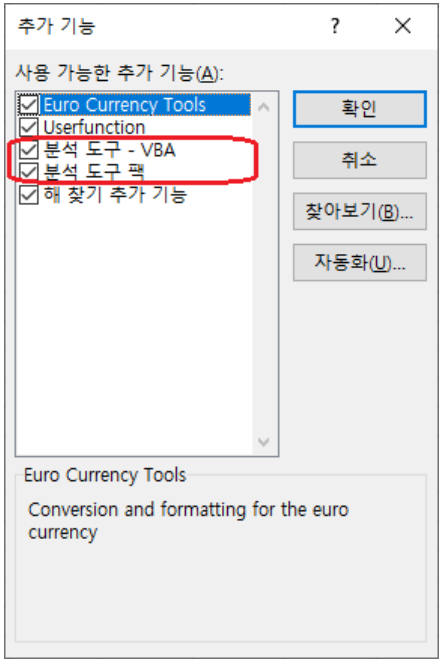

1. 퀴즈1

기술통계

기술통계는 데이터 → 분석 → 데이터 분석 메뉴를 선택한다.

통계 데이터 분석 창에서 기술 통계법 메뉴를 선택한다.

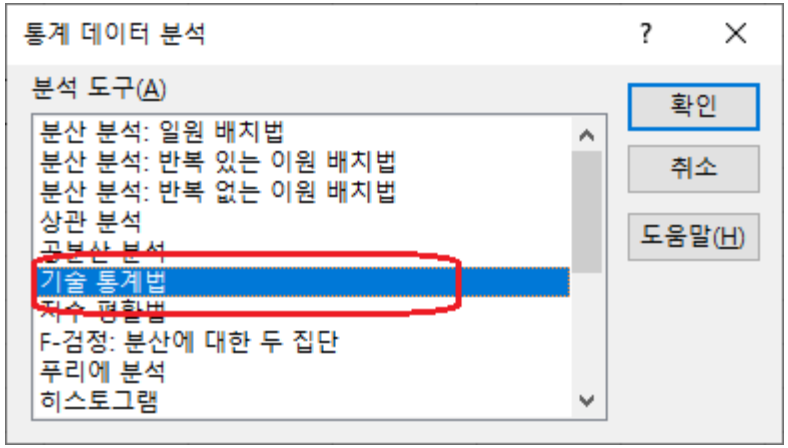

기술통계

기술 통계법 창에 입력 범위, 데이터 방향, 출력범위, 출력 값을 설정한다.

- 입력범위 : 마우스 드래그로 선택한다.
- 데이터 방향 : 데이터 배열을 행과 열 중 선택한다.
- 출력 범위 : 출력은 현 시트인지, 새로운 시트인지 선택한다.
- 출력 값 : 요약통계량, 신뢰구간, 최대값, 최소값 중 적어도 한 개 이상 선택한다.

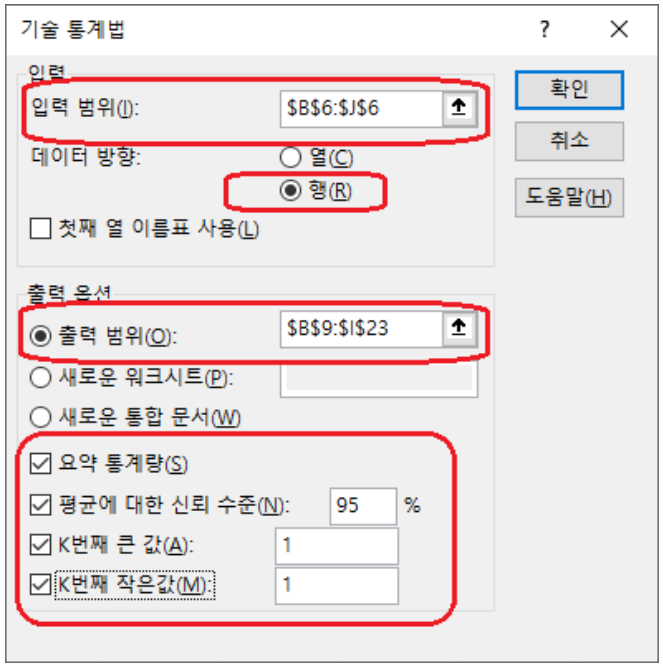

1. 퀴즈1

기술통계

분석할 자료는 데이터 배열이 행 방향이다.

전구 회사에서 전구 수명이 1100 시간 이상이라고 주장한다.
일부 소비자가 이 주장에 대하여 이의 제기하려고 다음 자료를 얻었다.
평균 수명이 1100미만인지 검정해보자

1100	1200	980	1230	950	990	1050	1120	1190

분석한 결과이다.

전구 회사에서 전구 수명이 1100 시간 이상이라고 주장한다.
일부 소비자가 이 주장에 대하여 이의 제기하려고 다음 자료를 얻었다.
평균 수명이 1100미만인지 검정해보자

1100	1200	980	1230	950	990	1050	1120	1190

	Row1
평균	1090
표준 오차	34.56074
중앙값	1100
최빈값	#N/A
표준 편차	103.6822
분산	10750
첨도	-1.64045
왜도	-0.00519
범위	280
최소값	950
최대값	1230
합	9810
관측수	9
가장 큰 값	1230
가장 작은	950
신뢰 수준(	79.6972

1. 퀴즈1

일표본 평균 비교

다음은 일표본 자료이다.

전구 회사에서 전구 수명이 1100 시간 이상이라고 주장한다.
일부 소비자가 이 주장에 대하여 이의 제기하려고 다음 자료를 얻었다.
평균 수명이 1100미만인지 검정해보자

1100	1200	980	1230	950	990	1050	1120	1190

분석한 결과이다.

귀무가설 설정 : 이미 알고 있는 평균 1100을 입력한다.
표본평균 : 자료에서 계산 =AVERAGE(B6:J6)
표본표준편차 : 자료에서 계산 =STDEV.S(B6:J6)
검정통계량 : =(C10-C8)/(F10/SQRT(I10))
유의확률 : =NORM.S.DIST(C12,TRUE)

1. 퀴즈1

일표본 평균 비교

검정결과 유의확률이 0.05보다 작기 때문에 귀무가설을 기각할 수 없다. 따라서 전구 수명이 1100 이하라고 일부 소비자자 주장은 통계적으로 의미가 없다.

C14 =NORM.S.DIST(C12,TRUE)

	A	B	C	D	E	F	G	H	I	J
1										
2		전구 회사에서 전구 수명이 1100 시간 이상이라고 주장한다.								
3		일부 소비자가 이 주장에 대하여 이의 제기하려고 다음 자료를 얻었다.								
4		평균 수명이 1100미만인지 검정해보자								
5										
6		1100	1200	980	1230	950	990	1050	1120	1190
7										
8		귀무가설	1100							
9										
10		표본평균	1090		표준편차	103.6822		표본수	9	
11										
12		검정통계량	-0.28935							
13										
14		유의확률	0.386158							
15										

1. 퀴즈1

대응 표본 비교

대응 표본 자료이다. 대응 표본 평균 비교는 쌍체비교, 대응비교 등으로 부른다.

캡사이신이 에탄올보다 혈류량을 증가시키는지 알아보려고 실험하였다.
한 마리 쥐의 귀를 임의로 선택하여 한 쪽에는 에탄올, 다른 쪽 귀에는 캡사이신을 투여하고
10분 뒤 양쪽 귀 혈류량을 측정하였다.

처리 \ 쥐	1	2	3	4	5	6	7	8	9
에탄올	208	285	181	251	277	281	232	135	240
캡사이신	791	572	604	766	942	664	643	372	559

1. 퀴즈1

대응 표본 비교

통계 데이터 분석 창에서 t-검정: 쌍체비교 메뉴를 선택한다.

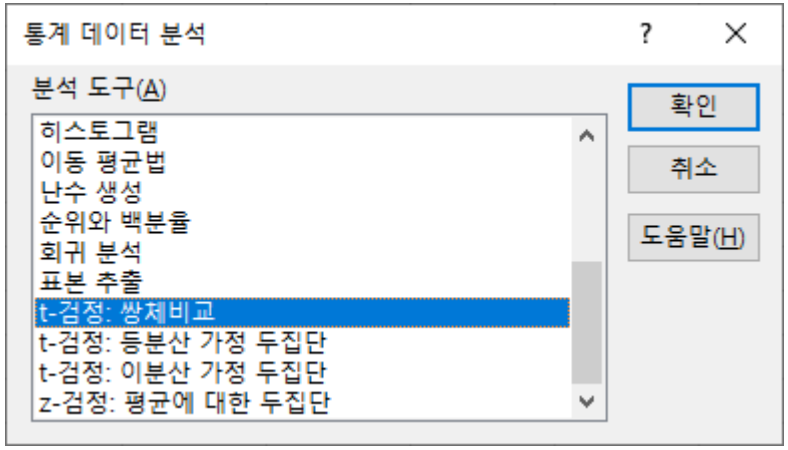

1. 퀴즈1

대응 표본 비교

대응 표본에 대한 분석결과이다. 유의확률이 1.76E−0.5=1.76×10^{-5}로 매우 작은값으로 유의한 결과가 나왔다. 따라서 켑사이신과 에탄올은 혈류량 흐름에 차이가 있다고 통계적으로 주장할 수 있다.

캡사이신이 에탄올보다 혈류량을 증가시키는지 알아보려고 실험하였다.
한 마리 쥐의 귀를 임의로 선택하여 한 쪽에는 에탄올, 다른 쪽 귀에는 캡사이신을 투여하고
10분 뒤 양쪽 귀 혈류량을 측정하였다.

처리 \ 쥐	1	2	3	4	5	6	7	8	9
에탄올	208	285	181	251	277	281	232	135	240
캡사이신	791	572	604	766	942	664	643	372	559

t-검정: 쌍체 비교

	변수 1	변수 2
평균	232.2222	657
분산	2530.694	26521.25
관측수	9	9
피어슨 상	0.565791	
가설 평균	0	
자유도	8	
t 통계량	-9.06054	
P(T<=t) 단	8.82E-06	
t 기각치 단	1.859548	
P(T<=t) 양	1.76E-05	
t 기각치 양	2.306004	

1. 퀴즈1

독립인 두 표본 비교

독립인 두 표본에 사용할 자료이다.

흡연자와 비흡연자의 혈중 페나세틴 대사과정이 차이가 있는지 조사하였다.

비흡연자	0.005	0.600	1.325	1.505	1.520	2.000	2.255	2.575	3.000	3.300	3.500
흡연자	0.005	0.005	0.255	0.505	0.525	1.000	1.250	1.505	1.750	2.750	

독립인 두 표본 평균 비교 전에 두 집단 평균이 같인지 검정한다. 통계 데이터 분석 창에서 F-검정: 분산에 대한 두 집단 메뉴를 선택한다.

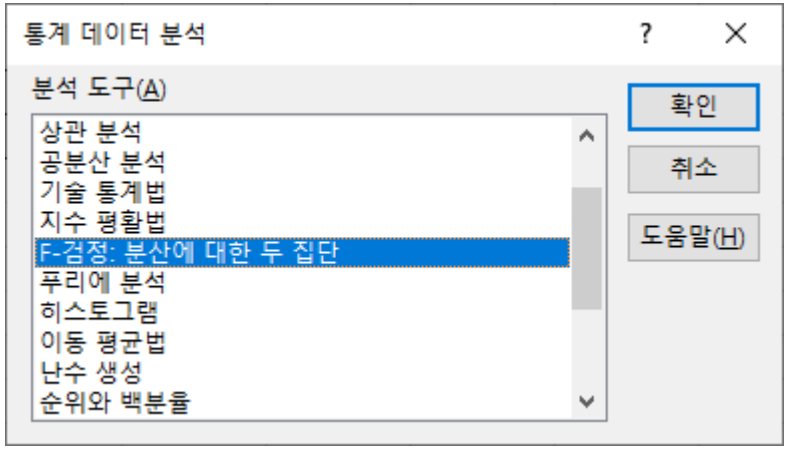

1. 퀴즈1

독립인 두 표본 비교

F-검정: 분산에 대한 두 집단 창에

- 변수 1 입력 범위: 변수이름을 포함한 첫 번째 자료 입력
- 변수 2 입력 범위: 변수이름을 포함한 두 번째 자료 입력
- 이름표: 변수도 포함시켰기에 를 선택
- 출력범위: 결과가 출력될 범위를 적당히 설정한다.

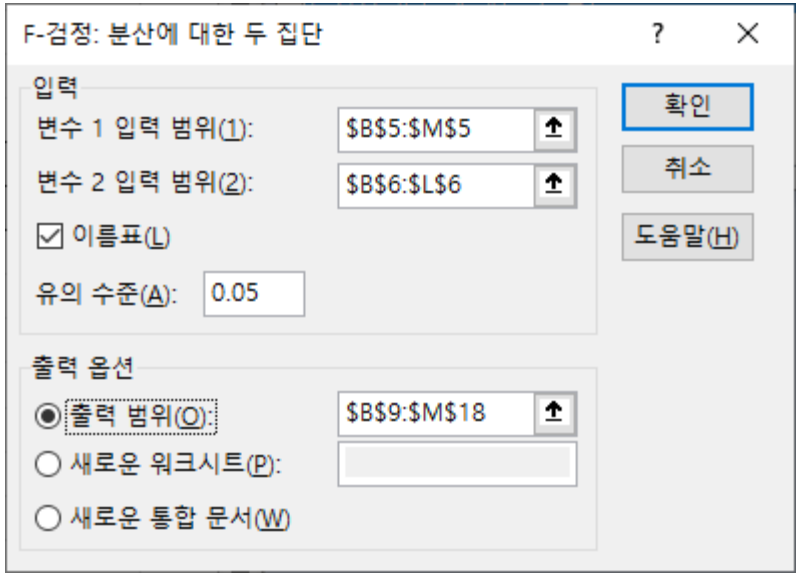

독립인 두 표본 비교

두 집단 분산의 동일성 검정 결과 유의확률이 0.250774로 유의수준 0.05에서 기각할 수 없다. 따라서 두 집단의 분산은 통계적으로 같다.

F-검정: 분산에 대한 두 집단

	비흡연자	흡연자
평균	1.962273	0.955
분산	1.219107	0.769778
관측수	11	10
자유도	10	9
F 비	1.583713	
P(F<=f) 단	0.250774	
F 기각치: 단	3.13728	

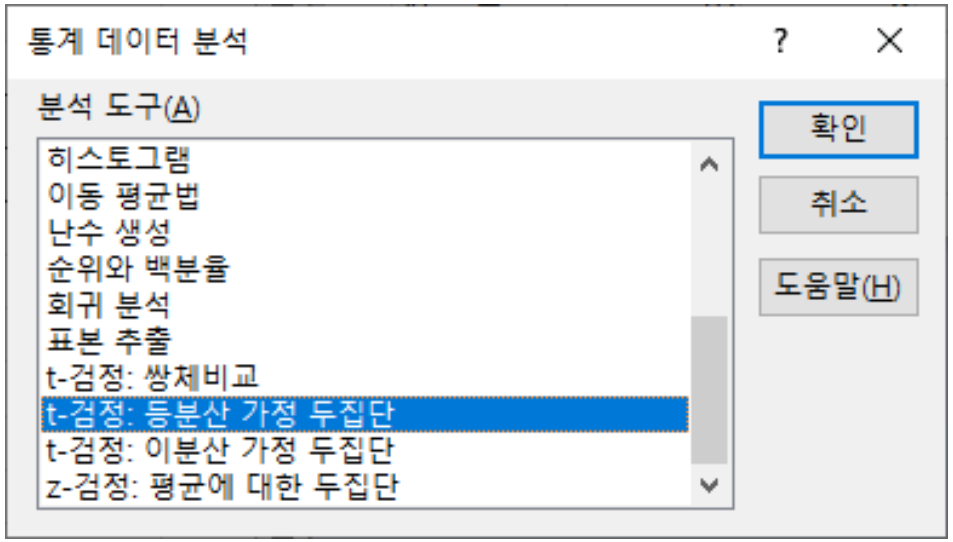

두 집단 평균 비교는 두 집단의 분산이 같다고 결론지었기에 t-검정: 등분산 가정 두집단 메뉴를 선택한다.

1. 퀴즈1

독립인 두 표본 비교

t-검정: 등분산 가정 두집단 창에

- 변수 1 입력 범위: 변수명을 포함한 첫 번째 자료 입력
- 변수 2 입력 범위: 변수명을 포함한 두 번째 자료 입력
- 가설 평균차 : 두 변수의 평균차이로 두 집단 평균 비교이므로 대부분 0
- 유의수준 : 0.05
- 이름표 : 데이터 입력할 때, 변수명도 포함되었기에 이름표 선택
- 출력범위 : 출력결과가 포함될 범위로 적당하게 설정

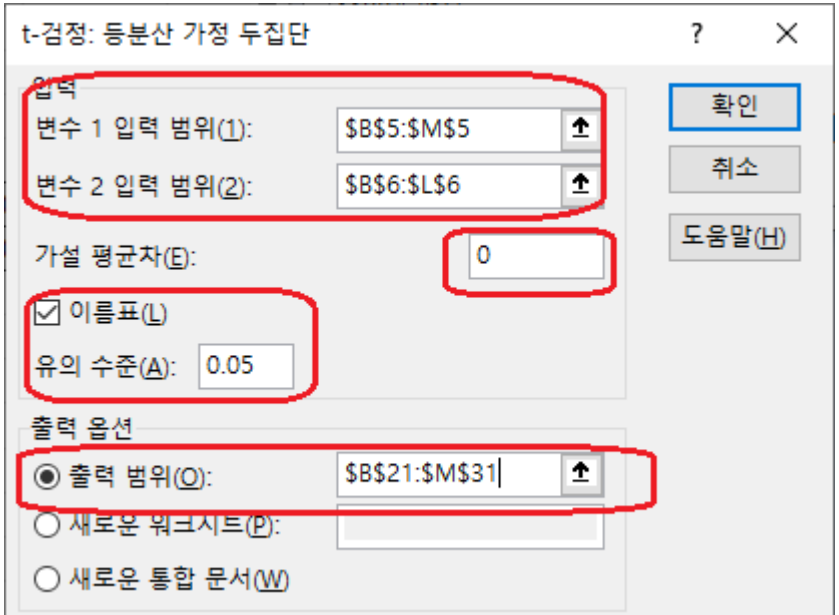

1. 퀴즈1

독립인 두 표본 비교

두 집단 평균 비교에 대한 검정결과 유의확률이 0.0330으로 유의한 값이 나왔으므로 두 집단 평균은 통계적으로 같지 않다.

t-검정: 등분산 가정 두 집단

	비흡연자	흡연자
평균	1.962273	0.955
분산	1.219107	0.769778
관측수	11	10
공동(Poole	1.006267	
가설 평균	0	
자유도	19	
t 통계량	2.298144	
P(T<=t) 단	0.016539	
t 기각치 단	1.729133	
P(T<=t) 양	0.033078	
t 기각치 양	2.093024	

1. 퀴즈1

분산분석 : 일원배치법

세 집단 이상 평균 비교는 분산분석을 이용하며 요인이 하나면 일원배치법이다.

사료 종류에 따른 체중 증가가 있는지 조사하려고 동물실험을 하였다.
사료 A는 이미 사용중인 사료이고 B,C,D는 새로 개발한 사료이다.
사료별 평균차이가 있는지 검정해보자.

사료 A	사료 B	사료 C	사료 D
60	62	68	56
59	67	67	60
59	63	71	59
58	64	70	57

분산분석 : 일원배치법

일원배치법 실행은 통계 데이터 분석 창에서 분산분석: 일원 배치법 메뉴를 선택한다.

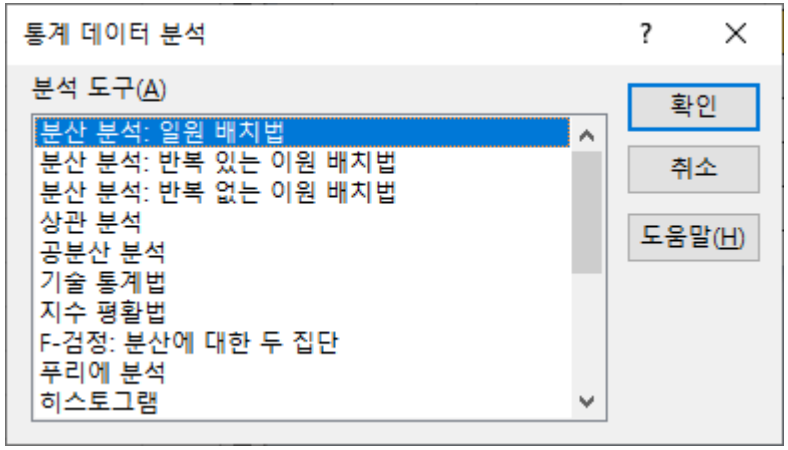

분산분석 : 일원배치법

분산분석: 일원 배치법 창에서

- 입력범위: 변수를 포함하여 분석할 자료를 마우스로 선택
- 데이터방향: 입력한 데이터 방향이 열, 행 중에 선택
- 첫째 행 이름표 사용: 데이터 범위에 변수명이 포함되었으면 선택
- 출력범위: 현재 시트에 출력될 범위를 적당히 선택

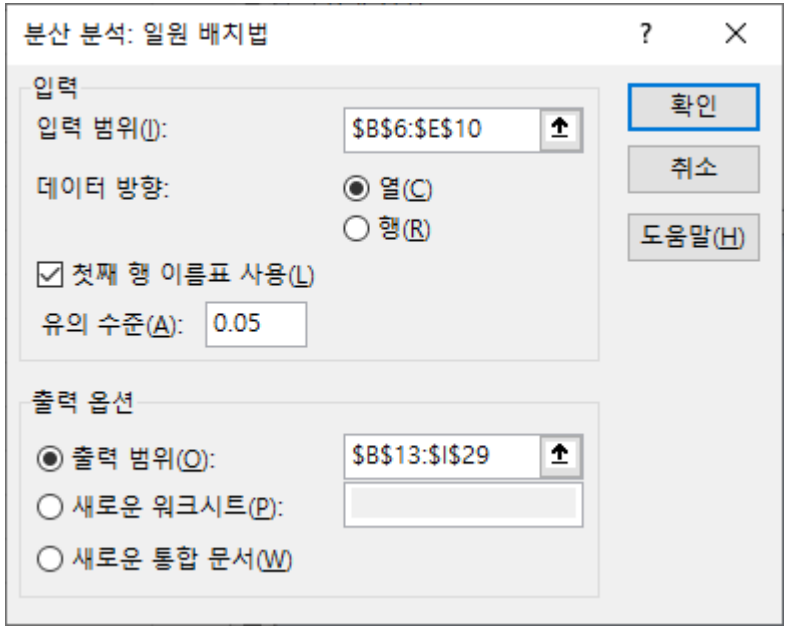

분산분석 : 일원배치법

출력결과는 각 변수에 대한 기초통계량과 분산분석표가 출력된다.
유의확률이 3.68E−0.6=3.68×10^{-6}으로 매우 유의한 값이 나왔으므로 네 집단의 평균은 통계적으로 모두 같지 않다.
이후 어떤 변수가 평균차이가 있는지 사후 분석은 이 분석도구에서 제공하지 않는다.

분산 분석: 일원 배치법

요약표

인자의 수준	관측수	합	평균	분산
사료 A	4	236	59	0.666667
사료 B	4	256	64	4.666667
사료 C	4	276	69	3.333333
사료 D	4	232	58	3.333333

분산 분석

변동의 요인	제곱합	자유도	제곱 평균	F 비	P-값	F 기각치
처리	308	3	102.6667	34.22222	3.68E-06	3.490295
잔차	36	12	3			
계	344	15				

1. 퀴즈1

분산분석 : 이원배치법

세 집단 이상 평균 비교는 분산분석을 이용하며 요인이 두 개이면 이원배치법이다.

다음은 세 가지 종류 비료(A)와 두 가지 농약(B)에 따른 작물 수확량이다.
비료와 농약에 따른 수확량 차이가 있는지 분석해보자.

농약 \ 비료	1	2	3
1	8	11	14
1	11	12	15
1	11	13	16
2	10	7	12
2	11	8	13
2	12	9	14

분산분석 : 이원배치법

분석할 자료는 요인이 2개이고 각 수준에서 반복 자료가 있어 반복이 있는 이원 배치 모형이다.

이원배치법 실행은 통계 데이터 분석 창에서 분산분석: 반복있는 이원 배치법 메뉴를 선택한다.

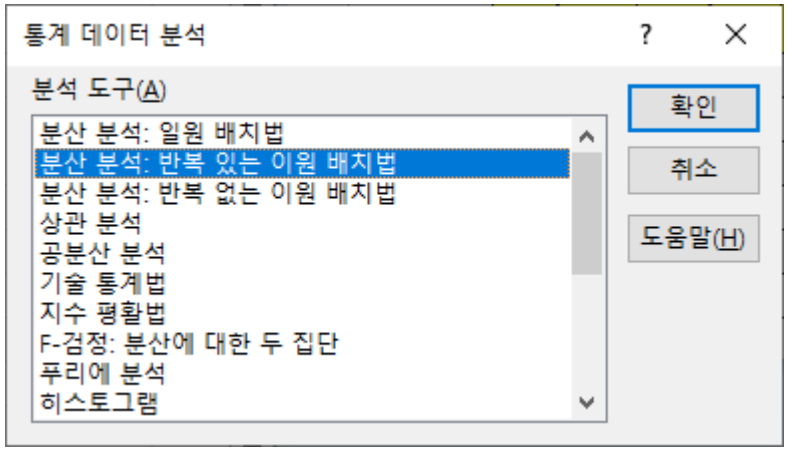

분산분석 : 이원배치법

분산분석: 반복있는 이원 배치법 창에서

- 입력 범위: 변수를 포함한 자료 범위 입력
- 표본당 행수: 반복할 행의 갯수를 입력
- 출력 범위: 현재 창에 분석결과가 출력될 범위를 적당히 설정

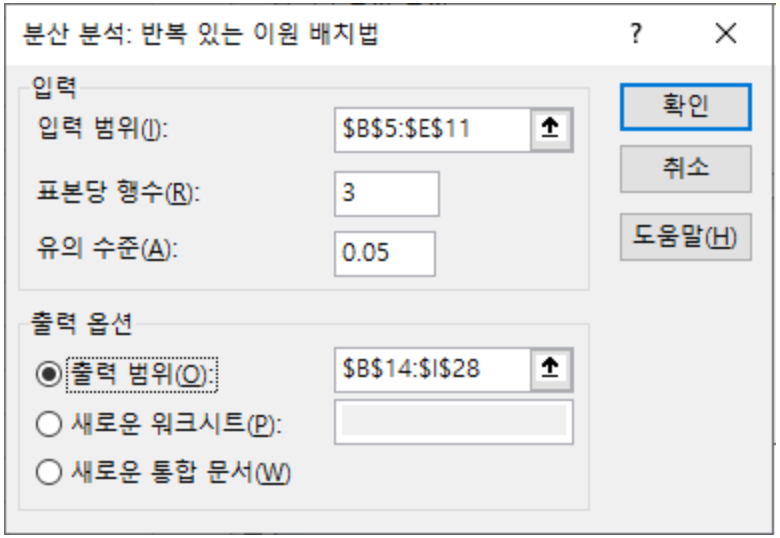

1. 퀴즈1

분산분석 : 이원배치법

출력결과 첫 번째 요인과 두 번째 요인에 대한 기초통계량을 출력하고 분산분석표도 함께 보여준다.
분석결과 인자 A (행)는 유의확률이 0.009864849이고 인자 B(열)는 유의확률이 0.000110862이다. 두 인자 모두 매우 유의한 결과로 통계적으로 평균은 모두 같지 않다.

분산 분석: 반복 있는 이원 배치법

요약표	1	2	3	계
1				
관측수	3	3	3	9
합	30	36	45	111
평균	10	12	15	12.33333
분산	3	1	1	6
2				
관측수	3	3	3	9
합	33	24	39	96
평균	11	8	13	10.66667
분산	1	1	1	5.5
계				
관측수	6	6	6	
합	63	60	84	
평균	10.5	10	14	
분산	1.9	5.6	2	

분산 분석

변동의 요인	제곱합	자유도	제곱 평균	F 비	P-값	F 기각치
인자 A(행)	12.5	1	12.5	9.375	0.009865	4.747225
인자 B(열)	57	2	28.5	21.375	0.000111	3.885294
교호작용	19	2	9.5	7.125	0.009127	3.885294
잔차	16	12	1.333333			
계	104.5	17				

2. 퀴즈2

자료 준비

dataanalytics.xlsx

2. 퀴즈2

한 표본 비율 비교

어떤 특정한 암의 경우에 수술을 시행한 후 완치되는 비율이 30%로 알려져 있다. 이 암에 걸린 60명의 환자를 대상으로 수술 뿐 아니라 수술 전후에 일정기간 방사선 치료를 병행하였더니 60명 중 27명이 완치되었다고 한다. 이 자료로부터 수술만 하는 것보다 방사선치료를 병행하는 것이 암의 완치율(p)을 높이는데 효과가 있다고 할 수 있는지 알아하자.

완치유무	환자수
완치	27
치료중	33
합계	60

2. 퀴즈2

한 표본 비율 비교

기대값을 계산한다. 기대값은 nxpi로 계산한다. 기대값은 전체 개수n , 각 비율 pi로 계산하면 60x0.3=18과 60x0.7=42가 된다.

관측값과 기대값을 계산한 결과이다.

완치유무	환자수	기대값
완치	27	18
치료중	33	42
합계	60	60

2. 퀴즈2

한 표본 비율 비교

=CHISQ.TEST 함수에 관측값과 기대값을 입력한다.

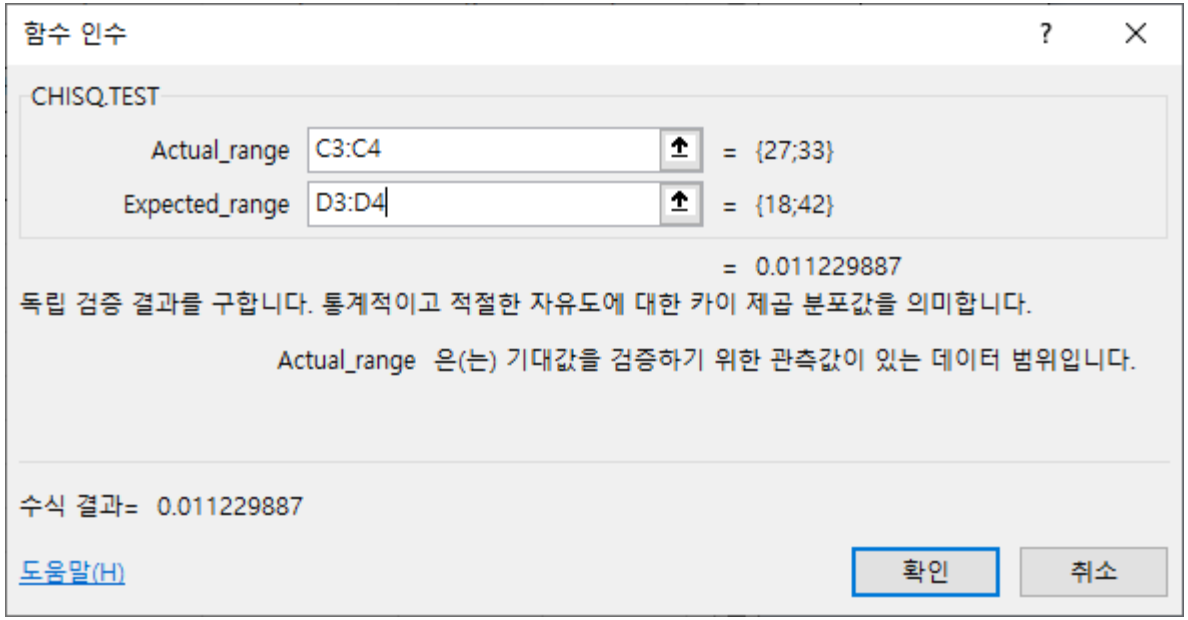

2. 퀴즈2

한 표본 비율 비교

유의확률을 계산하였다. 유의확률이 0.01123으로 0.05보다 작기 때문에 방사선을 병행한 치료 후 완치 비율은 30%보다 통계적으로 크다.

완치유무	환자수	기대값
완치	27	18
치료중	33	42
합계	60	60
유의확률	0.01123	

자동차 색깔에 대한 선호도를 다음과 같이 조사하였다. 자동차 색깔 선호도 비율은 모두 같은지 알아보자.

자주색 계열	파란색 계열	베이지색 계열	검정색 계열	흰색 계열
5	7	23	15	50

2. 퀴즈2

한 표본 비율 비교

관측값과 기대값을 계산한 결과이다.

	색 계열	파란색 계열	베이지색 계열	검정색 계열	흰색 계열
관측값	5	7	23	15	50
기대값	20	20	20	20	20

=CHISQ.TEST 함수에 관측값과 기대값을 입력한다.

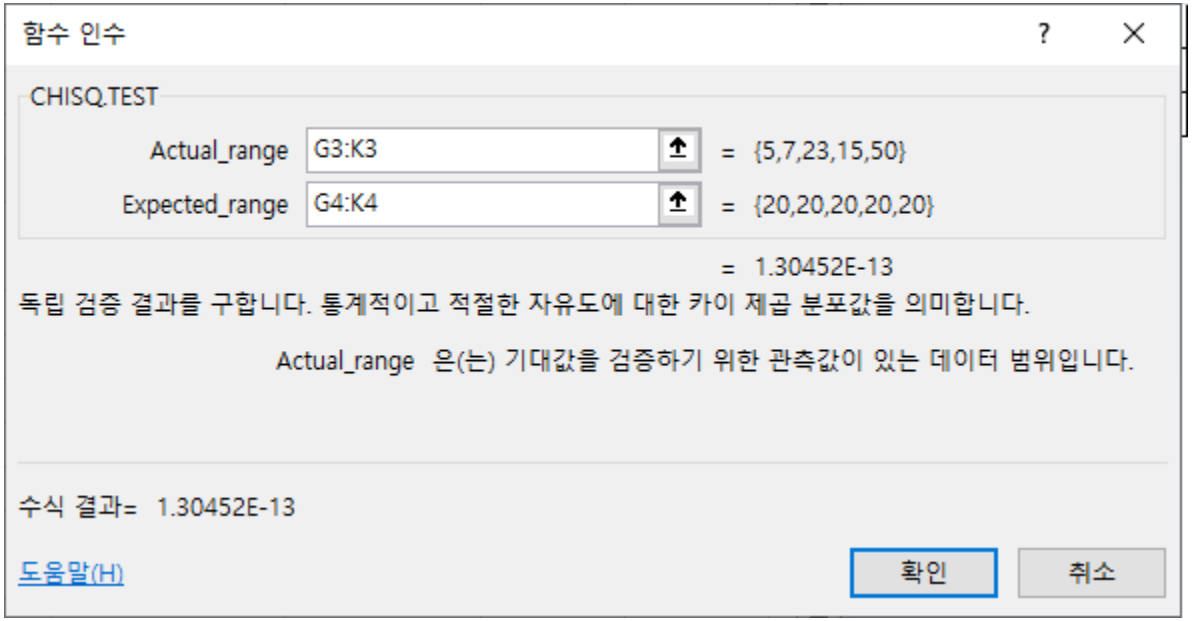

2. 퀴즈2

한 표본 비율 비교

유의확률을 계산하였다. 유의확률이 1.30452E−13=1.30452×10^{-13} 으로 0.05보다 작기 때문에 차량 색 선호도는 통계적으로 모두 같지 않다.

	색 계열	파란색 계열	베이지색 계열	검정색 계열	흰색 계열
관측값	5	7	23	15	50
기대값	20	20	20	20	20
유의확률	1.30452E-13				

χ^2값은 =CHISQ.INV.RT(유의확률,자유도) 로 구하며 값은 66.4로 계산되었다. 범주 갯수를 k라고 하면 자유도는 k-1이다.

2. 퀴즈2

두 표본 비율 비교

200명 환자를 100명씩 임의로 두 그룹으로 나누어 한 그룹에 새로 개발한 신약을 투여하고 다른 집단은 위약을 투여하고 환자 반응을 조사하였다.

처방	아주 좋음	조금 좋음	없음	합
신약	45	25	30	100
위약	30	30	40	100
합	75	55	70	200

2. 퀴즈2

두 표본 비율 비교

관측값과 기대값을 계산한 결과이다.

효과 / 처방	아주 좋음	조금 좋음	없음	합
신약	45	25	30	100
위약	30	30	40	100
합	75	55	70	200

효과 / 처방	아주 좋음	조금 좋음	없음	합
신약	37.5	27.5	35	100
위약	37.5	27.5	35	100
합	75	55	70	200

2. 퀴즈2

두 표본 비율 비교

=CHISQ.TEST 함수에 관측값과 기대값을 입력한다.

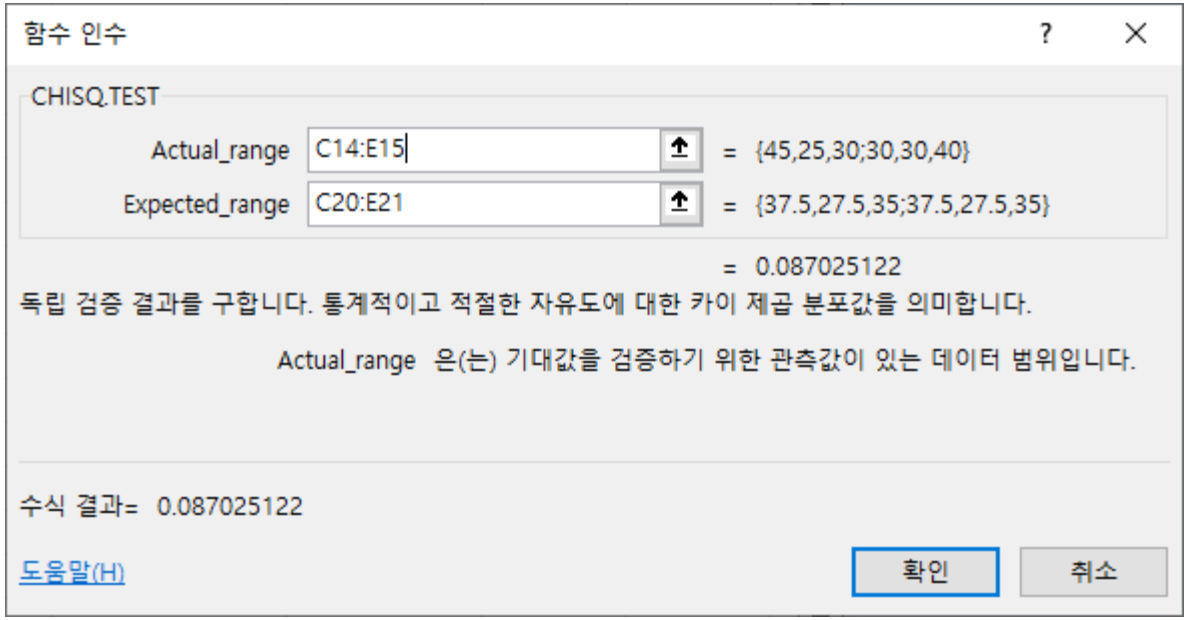

2. 퀴즈2

두 표본 비율 비교

유의확률을 계산하였다. 유의확률이 0.087025으로 0.05보다 크기 때문에 신약은 통계적으로 효과가 없다.

효과 / 처방	아주 좋음	조금 좋음	없음	합
신약	45	25	30	100
위약	30	30	40	100
합	75	55	70	200

효과 / 처방	아주 좋음	조금 좋음	없음	합
신약	37.5	27.5	35	100
위약	37.5	27.5	35	100
합	75	55	70	200

유의확률	0.087025			